Baza danych

Baza danych **AutoSprzedam.dat**. Baza pochodzi z zasobów zgormadzonych na ePortalu.

Zawartość

Baza danych zawiera 41034 rekordów zawierających szczegółowe dane dotyczące sprzedaży samochodów m.in.

Kolumna	Typ danych	Opis
NrOferty	int	Numer oferty sprzedaży samochodu.
CenaPLN	string	Cena samochodu wyrażona w polskich złotych (PLN).
KM	int	Liczba koni mechanicznych samochodu.
Marka	string	Marka samochodu.
Model	string	Model samochodu.
LiczbaDrzwi	string	Liczba drzwi w samochodzie.
PojemnoscSkokowa	int	Pojemność skokowa silnika wyrażona w centymetrach sześciennych (cm^3).
PrzebiegKm	int	Przebieg samochodu wyrażony w kilometrach.
RodzajPaliwa	string	Rodzaj paliwa używanego przez samochód (benzyna, diesel, hybryda, elektryczny itp.).
RokProdukcji	int	Rok produkcji samochodu.
Kolor	string	Kolor samochodu.
KrajPochodzenia	string	Kraj pochodzenia samochodu.
PojazdUszkodzony	string	Informacja czy pojazd jest uszkodzony (Tak/Nie).
SkrzyniaBiegow	string	Typ skrzyni biegów w samochodzie (manualna, automatyczna).

Podstawowe dana dotyczące bazy danych

```
## Liczba rekordów: 41034 , liczba kolumn: 14
```

```
## - Przykład  5 pierwszych rekordów.
```

```
##   NrOferty CenaPLN  KM         Marka         Model LiczbaDrzwi PojemnoscSkokowa
## 1        1   27900 150          Opel        Vectra         4/5             1900
## 2        2   28000 116        Toyota Corolla Verso         4/5             2000
## 3        3   25500 150         Skoda        Superb         4/5             1781
## 4        4   29900 109 Mercedes-Benz         A 180         2/3             1991
## 5        5   29800 207       Peugeot           607         4/5             2946
##   PrzebiegKm           RodzajPaliwa RokProdukcji             Kolor
## 1      80840 olej napędowy (diesel)         2005    czarny-metallic
## 2     166000 olej napędowy (diesel)         2004              bialy
## 3     112000            benzyna+LPG         2002   bordowy-metallic
## 4      42000 olej napędowy (diesel)         2005           czerwony
## 5     169000                benzyna         2004 granatowy-metallic
##   KrajPochodzenia PojazdUszkodzony SkrzyniaBiegow
## 1          Niemcy              Nie       manualna
## 2          Polska              Nie       manualna
## 3          Polska              Nie       manualna
## 4          Polska              Nie       manualna
## 5         Francja              Nie       manualna
```

```
## -  Przykład  5 ostatnich rekordów.
```

```
##       NrOferty  CenaPLN  KM         Marka    Model LiczbaDrzwi PojemnoscSkokowa
## 41030    41030 98000.00 220          Opel Insignia         4/5             1998
```

```
## 41031    41031 34924.50 184 Mercedes-Benz    S 400         4/5             3996
## 41032    41032 41175.09  70       Peugeot      308         2/3             1397
## 41033    41033 47900.00 115          Ford    C-MAX         4/5             1560
## 41034    41034 14200.00  90          Ford   Mondeo         4/5             1998
##       PrzebiegKm           RodzajPaliwa RokProdukcji              Kolor
## 41030      25500                benzyna         2010 grafitowy-metallic
## 41031     162000 olej napędowy (diesel)         2001   srebrny-metallic
## 41032       9289                benzyna         2010   srebrny-metallic
## 41033      45000 olej napędowy (diesel)         2010    czarny-metallic
## 41034     191024 olej napędowy (diesel)         2003    czarny-metallic
##       KrajPochodzenia PojazdUszkodzony SkrzyniaBiegow
## 41030          Polska              Nie       manualna
## 41031          Czechy              Nie   automatyczna
## 41032          Niemcy              Nie       manualna
## 41033          Belgia              Nie       manualna
## 41034          Niemcy              Nie       manualna
```

Przygotowanie bazy danych

Przed przejściem do dalszej pracy z bazą danych konieczne jest jej przygotowanie.

Pole - *SkrzyniaBiegow*

W bazie występują 3 rodzaje typów skrzyni biegów: *półautomatyczna/sekwencyjna*, *manualna* oraz *automatyczna*. Udział typu *półautomatyczna/sekwencyjna* w całej bazie wynosi 1,5%.

W związku z niewielkim udziałem ze skrzynią *półautomatyczna/sekwencyjna*, typ ten został usunięty z bazy. Dzięki czemu możliwe jest przekształcenie kolumny *SkrzyniaBiegow* (char), na *SkrzyniaBiegowManualna* (bool).

```
## # A tibble: 3 x 2
##   `database$SkrzyniaBiegow`   liczba
##   <chr>                        <int>
## 1 automatyczna                  6941
## 2 manualna                     34030
## 3 półautomatyczna/sekwencyjna     63
```

```
## Udział pojazdów ze skrzynią biegów typu 'półautomatyczna/sekwencyjna' 0.1535312 %.
```

Pole *PojazdUszkodzony*

Domyślnym typem danych dla pola *PojazdUszkodzony* jest (char), gdzie zmienna jest typem logicznym. W związku z powyższym kolumna *PojazdUszkodzony* została przekształcona to typu *bool*.

Baza danych po wprowadzonych modyfikacjach

```
## Baza danych po wprowadzonych modyfikacjach
```

```
## Liczba rekordów: 40971 , liczba kolumn: 14
```

```
## - Przykład  5 pierwszych rekordów.
```

```
##   NrOferty CenaPLN  KM         Marka         Model LiczbaDrzwi PojemnoscSkokowa
## 1        1   27900 150          Opel        Vectra         4/5             1900
## 2        2   28000 116        Toyota Corolla Verso         4/5             2000
## 3        3   25500 150         Skoda        Superb         4/5             1781
## 4        4   29900 109 Mercedes-Benz         A 180         2/3             1991
```

```
## 5        5   29800 207       Peugeot           607         4/5             2946
##   PrzebiegKm           RodzajPaliwa RokProdukcji              Kolor
## 1      80840 olej napędowy (diesel)         2005    czarny-metallic
## 2     166000 olej napędowy (diesel)         2004              bialy
## 3     112000            benzyna+LPG         2002   bordowy-metallic
## 4      42000 olej napędowy (diesel)         2005           czerwony
## 5     169000                benzyna         2004 granatowy-metallic
##   KrajPochodzenia PojazdUszkodzony SkrzyniaBiegowManualna
## 1          Niemcy            FALSE                   TRUE
## 2          Polska            FALSE                   TRUE
## 3          Polska            FALSE                   TRUE
## 4          Polska            FALSE                   TRUE
## 5         Francja            FALSE                   TRUE
```

- Przykład 5 ostatnich rekordów.

```
##       NrOferty  CenaPLN  KM         Marka    Model LiczbaDrzwi PojemnoscSkokowa
## 41030    41030 98000.00 220          Opel Insignia         4/5             1998
## 41031    41031 34924.50 184 Mercedes-Benz    S 400         4/5             3996
## 41032    41032 41175.09  70       Peugeot      308         2/3             1397
## 41033    41033 47900.00 115          Ford    C-MAX         4/5             1560
## 41034    41034 14200.00  90          Ford   Mondeo         4/5             1998
##       PrzebiegKm           RodzajPaliwa RokProdukcji              Kolor
## 41030      25500                benzyna         2010 grafitowy-metallic
## 41031     162000 olej napędowy (diesel)         2001   srebrny-metallic
## 41032       9289                benzyna         2010   srebrny-metallic
## 41033      45000 olej napędowy (diesel)         2010    czarny-metallic
## 41034     191024 olej napędowy (diesel)         2003    czarny-metallic
##       KrajPochodzenia PojazdUszkodzony SkrzyniaBiegowManualna
## 41030          Polska            FALSE                   TRUE
## 41031          Czechy            FALSE                  FALSE
## 41032          Niemcy            FALSE                   TRUE
## 41033          Belgia            FALSE                   TRUE
## 41034          Niemcy            FALSE                   TRUE
```

Wyznaczenie podstawowych statystyk

Pole *CenaPLN*

Kolumna zawiera informacje o cenie po jakie asmochody zostału sprzedane w PLN.

Dane przed eliminacją danych odstających

```
summarise(database,
  srednia = mean(CenaPLN),
  mediana = median(CenaPLN),
  wariancja = var(CenaPLN),
  odchylenieStd = sd(CenaPLN),
  max = max(CenaPLN),
  min = min(CenaPLN),
)
```

```
##    srednia mediana  wariancja odchylenieStd     max  min
## 1 40848.35   26000 2636580628      51347.64 1788000 1000
```

```
ggplot(data=database) + geom_histogram(aes(x=CenaPLN), bins = 50) + ggtitle("Histogram dla cen sprzedaży
```

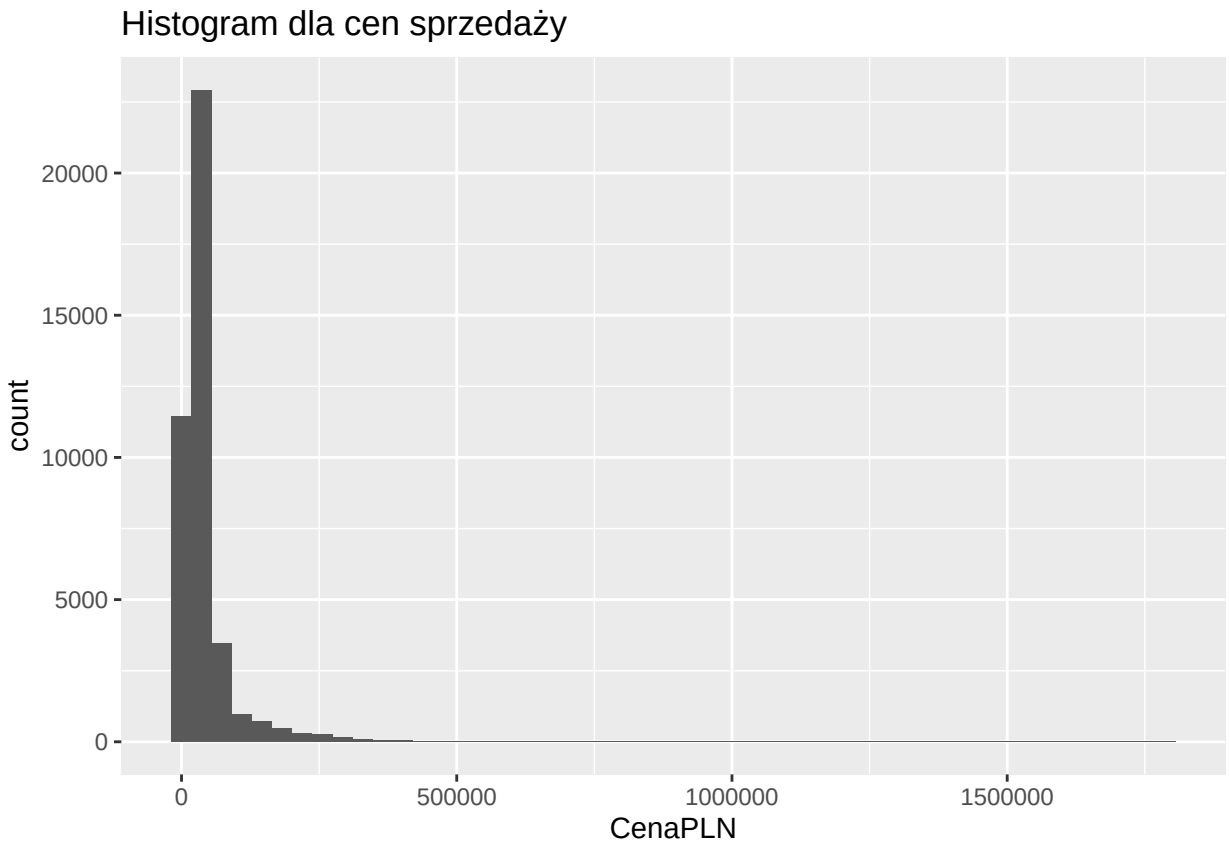


```
ggplot(data=database) + geom_boxplot(aes(x=CenaPLN)) + ggtitle("Wykres pudełko-wąsy dla cen sprzedaży")
```

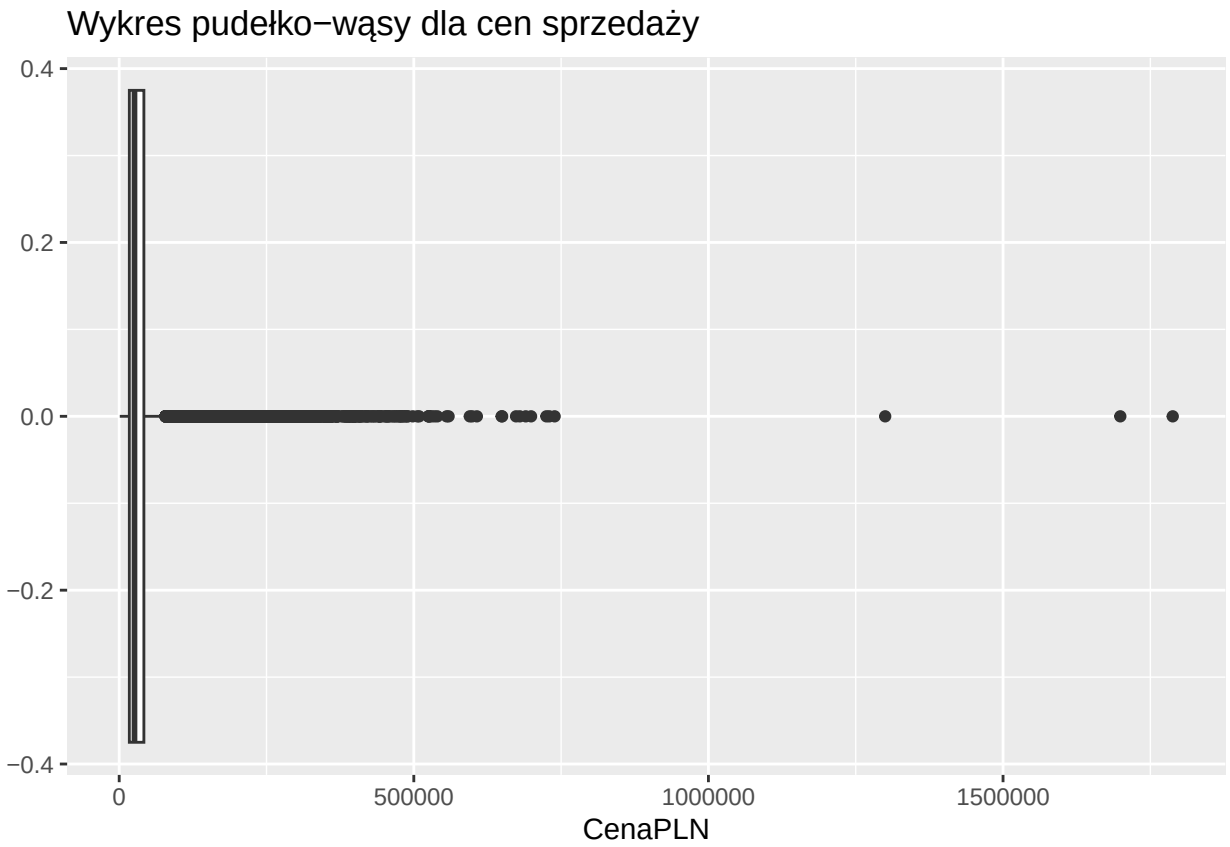


```
ggplot(data=database, aes(sample = CenaPLN)) + stat_qq() + stat_qq_line(colour="red") + ylab("Kwantyl T
  ggtitle("Wykres QQ dla cen sprzedaży") + theme(axis.text.x = element_blank(), axis.text.y = element_bl
```

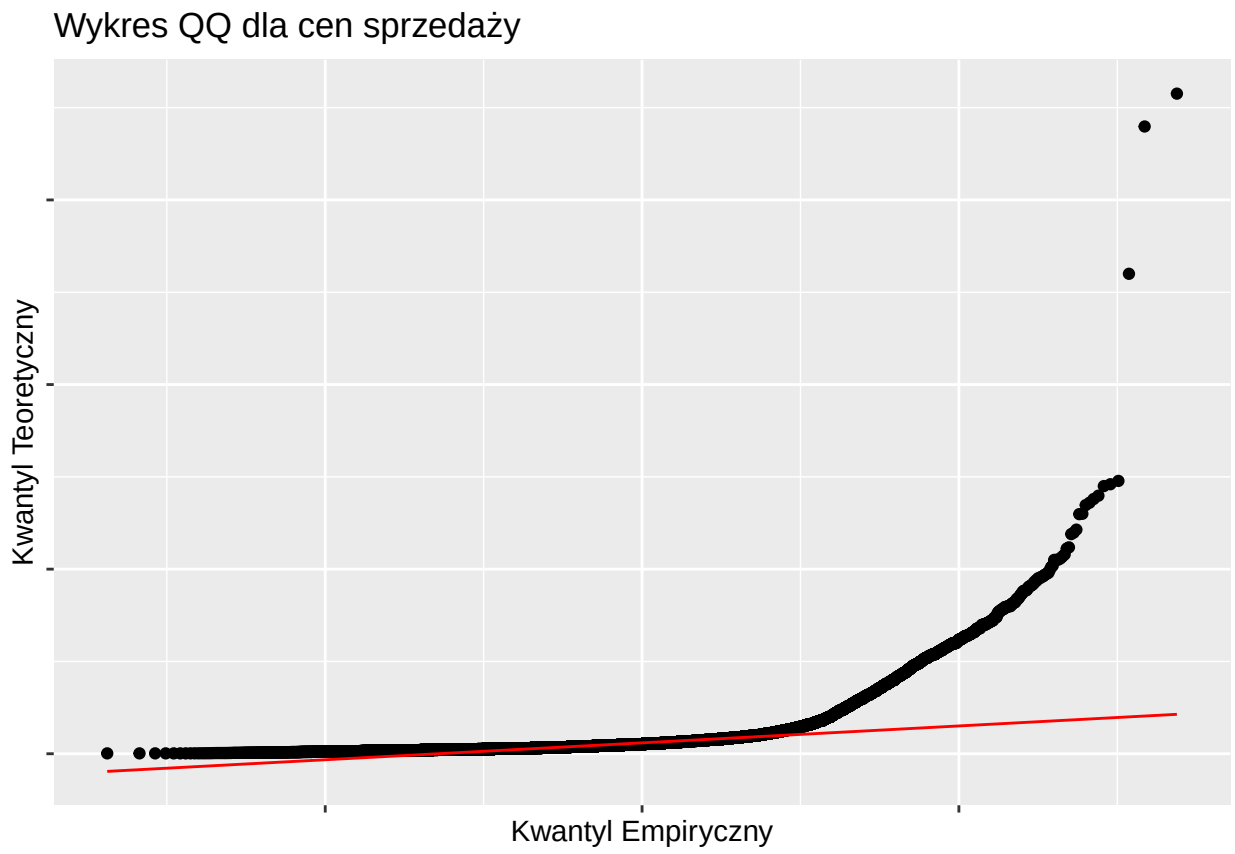

Redukcja danych odstających Redukcja danych zgodnie z regułą 3 sigma.

Identyfikacja danych odstających za pomocą reguły trzech sigm:

1. Obliczenie średniej (μ): Najpierw oblicza się średnią dla danego zbioru danych.
2. Obliczenie odchylenia standardowego (σ): Następnie oblicza się odchylenie standardowe, które mierzy, jak bardzo dane rozpraszają się wokół średniej.
3. Ustalenie zakresu trzech sigm: Wartości, które znajdują się poza zakresem trzech sigm ($\mu \pm 3\sigma$), są uznawane za dane odstające.

```
mean_price = mean(database$CenaPLN);
sd_price   = sd(database$CenaPLN);

lower_bound <- mean_price - 3 * sd_price;
upper_bound <- mean_price + 3 * sd_price;

cat("Wyznacznowe granice metodą 3 sigma \n")
```

```
## Wyznacznowe granice metodą 3 sigma
```

```
cat("Dolna granica ", lower_bound, ", górna granica ", upper_bound, "\n");
```

```
## Dolna granica  -113194.6 , górna granica  194891.3
```

```
cat("Dolna granica wykracza poza osiągane wartości kwot sprzedaży (ujemna wartość). \n")
```

```
## Dolna granica wykracza poza osiągane wartości kwot sprzedaży (ujemna wartość).
```

```r
upper_price_example = database[which(database$CenaPLN >= upper_bound),];
head(upper_price_example[order(upper_price_example$CenaPLN, decreasing = TRUE),])
```

```
##       NrOferty CenaPLN  KM         Marka      Model LiczbaDrzwi
## 14353    14353 1788000 626 Mercedes-Benz        SLR         4/5
## 36278    36278 1699000 800 Mercedes-Benz   S 63 AMG         4/5
## 14159    14159 1300000 626 Mercedes-Benz        SLR         2/3
## 27512    27512  739000 571 Mercedes-Benz SLS 63 AMG         2/3
## 28662    28662  730000 563 Mercedes-Benz SLS 63 AMG         2/3
## 28663    28663  725000 563 Mercedes-Benz SLS 63 AMG         2/3
##       PojemnoscSkokowa PrzebiegKm RodzajPaliwa RokProdukcji              Kolor
## 14353             5439          1      benzyna         2009    czarny-metallic
## 36278             6233       1500      benzyna         2011    czarny-metallic
## 14159             5439       2098      benzyna         2007 granatowy-metallic
## 27512             6208       5000      benzyna         2010 grafitowy-metallic
## 28662             6208        380      benzyna         2011    czarny-metallic
## 28663             6208        520      benzyna         2011   srebrny-metallic
##         KrajPochodzenia PojazdUszkodzony SkrzyniaBiegowManualna
## 14353           Niemcy            FALSE                  FALSE
## 36278           Niemcy            FALSE                  FALSE
## 14159           Niemcy            FALSE                  FALSE
## 27512           Polska            FALSE                  FALSE
## 28662 Stany Zjednoczone            FALSE                  FALSE
## 28663 Stany Zjednoczone            FALSE                  FALSE
```

```r
database = database[database$CenaPLN >= lower_bound & database$CenaPLN <= upper_bound,]
```

Redukcja danych odstających regułą odstępu międzykwartylowgo

Metoda redukcji, polega na wykrywaniu i usuwaniu wartości odstających z zestawu danych. Metoda ta opiera się na kwartylach i rozstępie międzykwartylowym.

1. Wyznaczenie *Q1* (pierwszy kwartyl) oraz *Q3* (trzeci kwartyl)
2. Wyznaczenie odstępu międzykwartylowego $IQR = Q3 - Q1$
3. Wyznaczenie dolnej $Q1 - 1.5 \times IQR$ oraz górnej $Q1 + 1.5 \times IQR$ granicy.

```r
Q1 = quantile(database$PrzebiegKm, 0.25);
Q3 = quantile(database$PrzebiegKm, 0.75);
IQR = Q3-Q1;
lower_bound = Q1 - 1.5*IQR #mniejsze niż
upper_bound = Q3 + 1.5*IQR #większe niż

cat("Wyznacznowe granice metodą 3 sigma \n")
```

```
## Wyznacznowe granice metodą 3 sigma
```

```r
cat("Dolna granica ", lower_bound, ", górna granica ", upper_bound, "\n");
```

```
## Dolna granica  -47281.25 , górna granica  303568.8
```

```r
cat("Dolna granica wykracza poza osiągane wartości kwot sprzedaży (ujemna wartość). \n")
```

```
## Dolna granica wykracza poza osiągane wartości kwot sprzedaży (ujemna wartość).
```

```r
database = database[database$PrzebiegKm >= lower_bound & database$PrzebiegKm <= upper_bound,]
```

```r
database %>% group_by(Marka) %>% summarise(liczbaSprzedanych = n(),
                                           sredniaCena = mean(CenaPLN),
                                           medianaCena = median(CenaPLN))
```

```
## # A tibble: 11 x 4
##    Marka         liczbaSprzedanych sredniaCena medianaCena
##    <chr>                     <int>       <dbl>       <dbl>
##  1 Audi                       3322      64178.      46900
##  2 BMW                        2217      61711.      51500
##  3 Fiat                       1923      19118.      14800
##  4 Ford                       5393      27389.      22900
##  5 Mercedes-Benz              2319      62040.      46000
##  6 Opel                       4991      24201.      22600
##  7 Peugeot                    3199      25212.      22000
##  8 Renault                    4714      21099.      17810.
##  9 Skoda                      2928      29156.      26450
## 10 Toyota                     2669      36048.      29900
## 11 Volkswagen                 6120      35673.      29900
```

Dane po eliminacją danych odstających

```r
summarise(database,
  srednia = mean(CenaPLN),
  mediana = median(CenaPLN),
  wariancja = var(CenaPLN),
  odchylenieStd = sd(CenaPLN),
  max = max(CenaPLN),
  min = min(CenaPLN),
)
```

```
##    srednia mediana wariancja odchylenieStd    max  min
## 1 34656.67   25900 870294063      29500.75 194800 1000
```

```r
ggplot(data=database) + geom_histogram(aes(x=CenaPLN), bins = 50) + ggtitle("Histogram dla cen sprzedaży
```

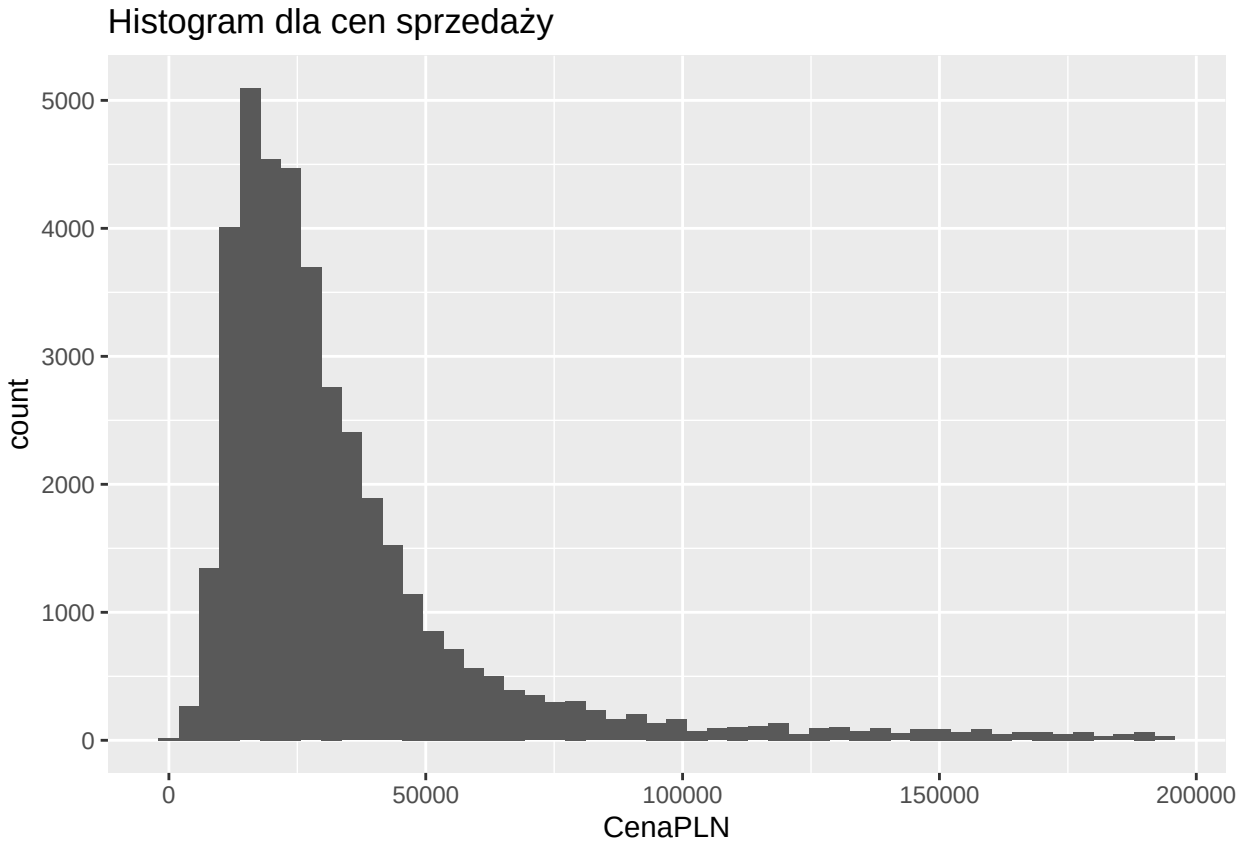


```
ggplot(data=database) + geom_boxplot(aes(x=CenaPLN)) + ggtitle("Wykres pudełko-wąsy dla cen sprzedaży")
```

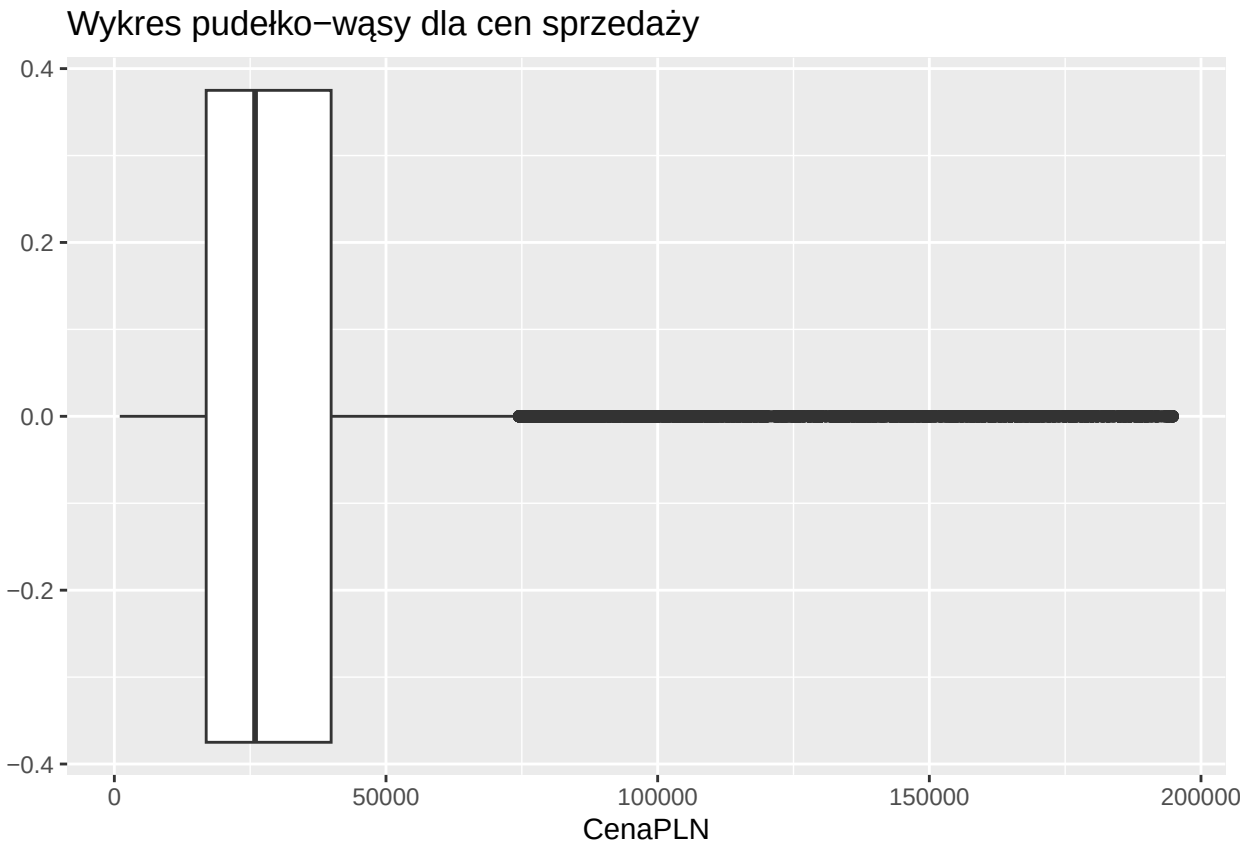


```
ggplot(data=database, aes(sample = CenaPLN)) + stat_qq() + stat_qq_line(colour="red") + ylab("Kwantyl T
  ggtitle("Wykres QQ dla cen sprzedaży") + theme(axis.text.x = element_blank(), axis.text.y = element_bl
```

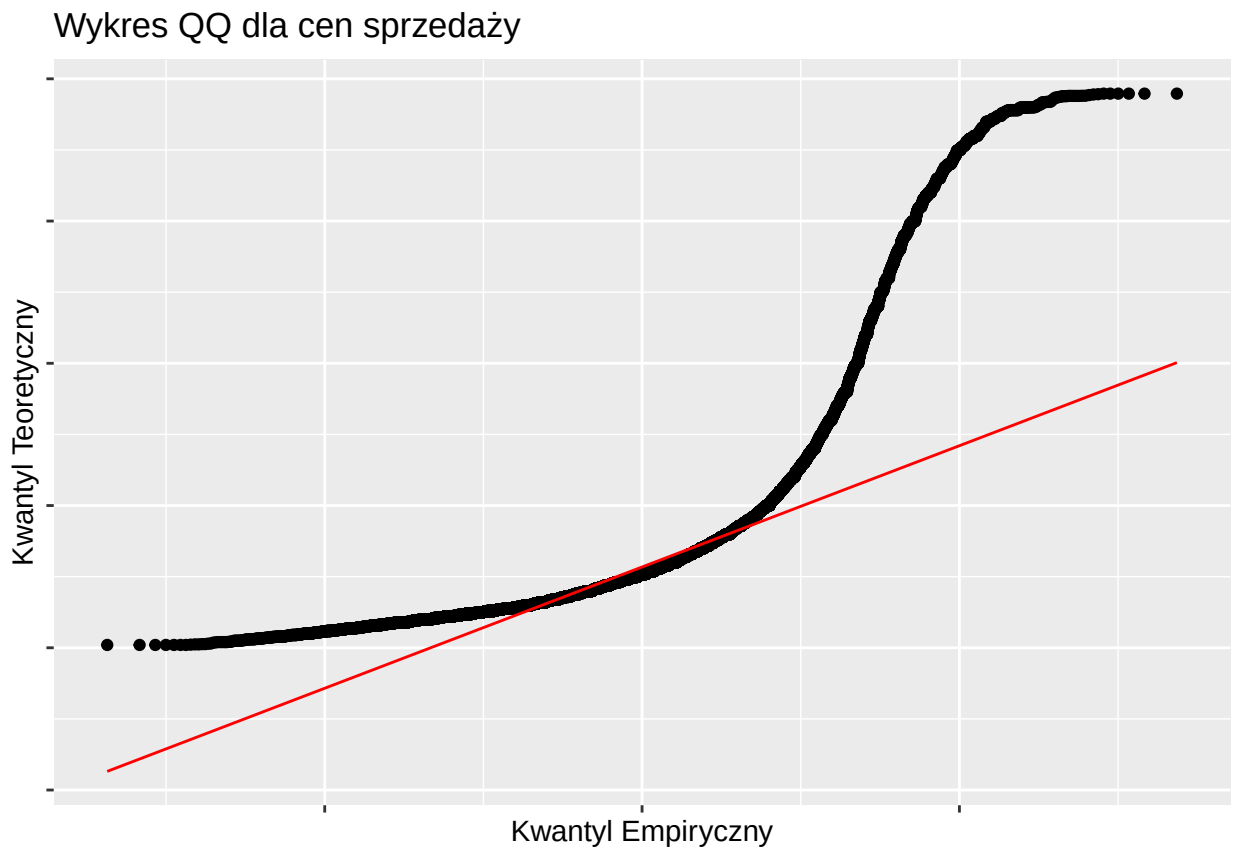


```
fuelType = database %>% group_by(database$RodzajPaliwa) %>% summarise(liczba = n());
colnames(fuelType) = c("FuelType", "Count");
fuelType = fuelType[order(fuelType$Count, decreasing = TRUE),]
fuelType
```

```
## # A tibble: 6 x 2
##   FuelType                Count
##   <chr>                   <int>
## 1 olej napędowy (diesel) 26980
## 2 benzyna                11878
## 3 benzyna+LPG              883
## 4 benzyna+CNG               23
## 5 hybryda                   21
## 6 napęd elektryczny         10
```

```
ggplot(fuelType, aes(x="", y=Count, fill=FuelType)) +
  geom_bar(stat="identity", width=1, color="white") +
  coord_polar("y", start=0) + theme_void();
```

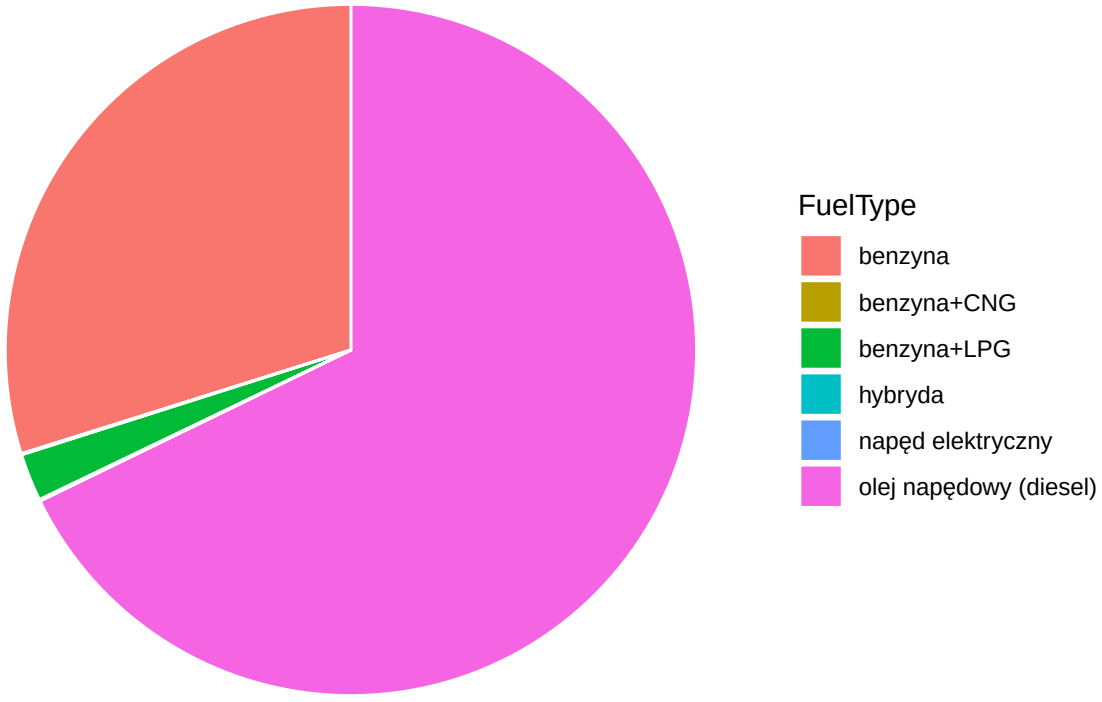

Liczba koni mechanicznych samochodu

```
summarise(database,
  srednia = mean(KM),
  mediana = median(KM),
  wariancja = var(KM),
  odchylenieStd = sd(KM),
  max = max(KM),
  min = min(KM),
)
```

```
##    srednia mediana wariancja odchylenieStd  max min
## 1 116.2776     106  2567.881      50.67426 1400   1
```

```
upper_price_example = database[which(database$CenaPLN >= upper_bound),];
head(upper_price_example[order(upper_price_example$CenaPLN, decreasing = TRUE),])
```

```
##  [1] NrOferty               CenaPLN                KM
##  [4] Marka                  Model                  LiczbaDrzwi
##  [7] PojemnoscSkokowa       PrzebiegKm             RodzajPaliwa
## [10] RokProdukcji           Kolor                  KrajPochodzenia
## [13] PojazdUszkodzony       SkrzyniaBiegowManualna
## <0 wierszy> (lub 'row.names' o zerowej długości)
```

```
ggplot(data=database)+ geom_histogram(aes(x=KM), binwidth = 20) + ggtitle("Histogram dla KM")
```

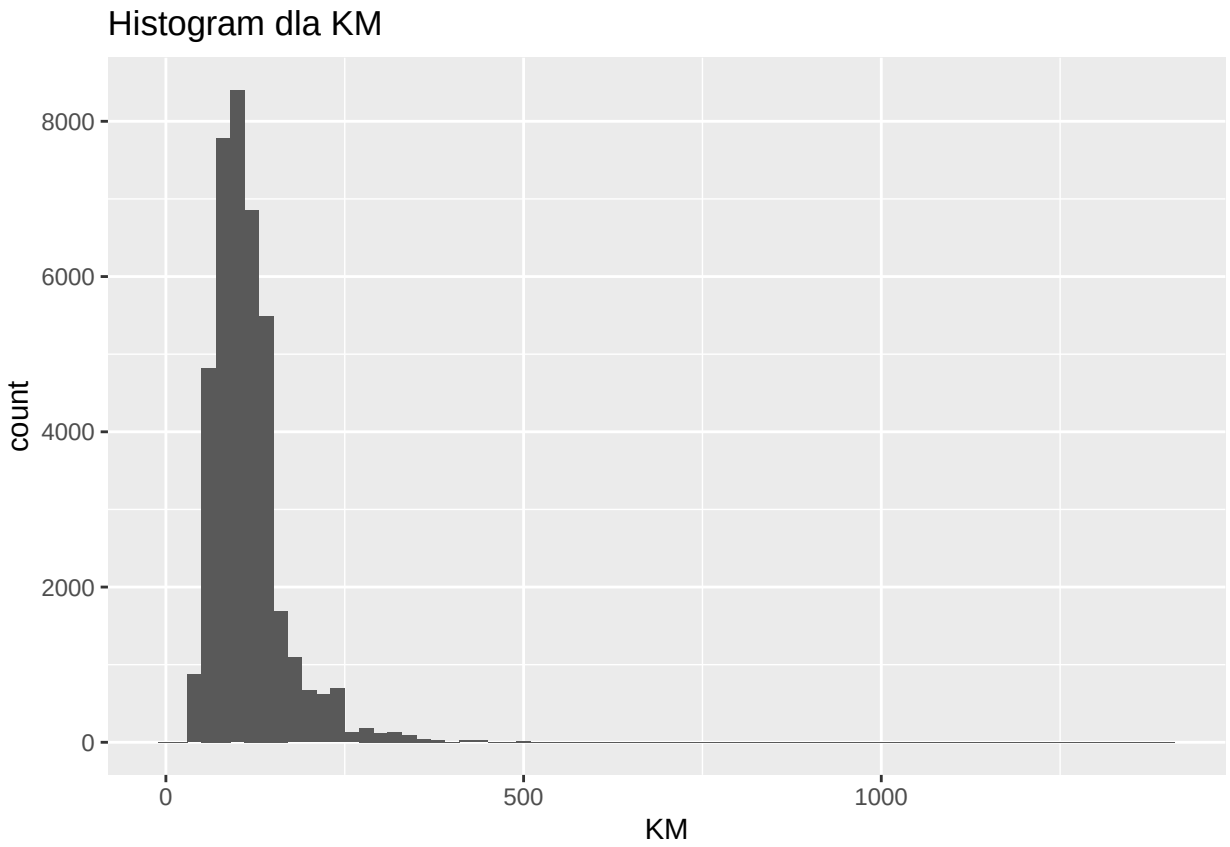

VI - Budowa macierzy z bazy danych

Do zbudowanie macierzy wykorzystano wszystkie dostępne numeryczne dane tj. *CenaPLN*, *KM*, *PrzebiegKm*, *RokProdukcji*, *PojemnoscSkokowa*. Dzięki temu możliwe jest wyznaczenie macierzy korelacji pomiędzy danymi.

```
# Select data
vi_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "KM", "PrzebiegKm", "RokProdukcji", "PojemnoscSkokowa"))

#Display head
head(vi_database)
```

```
##   CenaPLN  KM PrzebiegKm RokProdukcji PojemnoscSkokowa
## 1   27900 150      80840         2005             1900
## 2   28000 116     166000         2004             2000
## 3   25500 150     112000         2002             1781
## 4   29900 109      42000         2005             1991
## 5   29800 207     169000         2004             2946
## 6   21400 122     160000         2003             1800
```

```
# Dimension
vi_dim <- dim(vi_database);
cat("Rozmiar macierzy:", vi_dim[1], "x", vi_dim[2]);
```

```
## Rozmiar macierzy: 32646 x 5
```

```
# Columns mean
vi_means = round(colMeans(vi_database), 3);
cat(paste(names(vi_means), vi_means, sep = " : ", collapse = ",\n"))
```

```
## CenaPLN : 29250.103,
## KM : 104.378,
## PrzebiegKm : 127080.842,
## RokProdukcji : 2005.089,
## PojemnoscSkokowa : 1739.627
```

```
# Correlation
vi_corr_matrix = cor(vi_database);
print(vi_corr_matrix)
```

```
##                    CenaPLN        KM PrzebiegKm RokProdukcji PojemnoscSkokowa
## CenaPLN          1.0000000 0.5096861 -0.3659806   0.62332163       0.38550218
## KM               0.5096861 1.0000000  0.1047219   0.07592120       0.73909520
## PrzebiegKm      -0.3659806 0.1047219  1.0000000  -0.57854449       0.30351805
## RokProdukcji     0.6233216 0.0759212 -0.5785445   1.00000000      -0.09648703
## PojemnoscSkokowa 0.3855022 0.7390952  0.3035180  -0.09648703       1.00000000
```

```
corrplot(vi_corr_matrix, order = "hclust",
         tl.col = "black", tl.srt = 45)
```

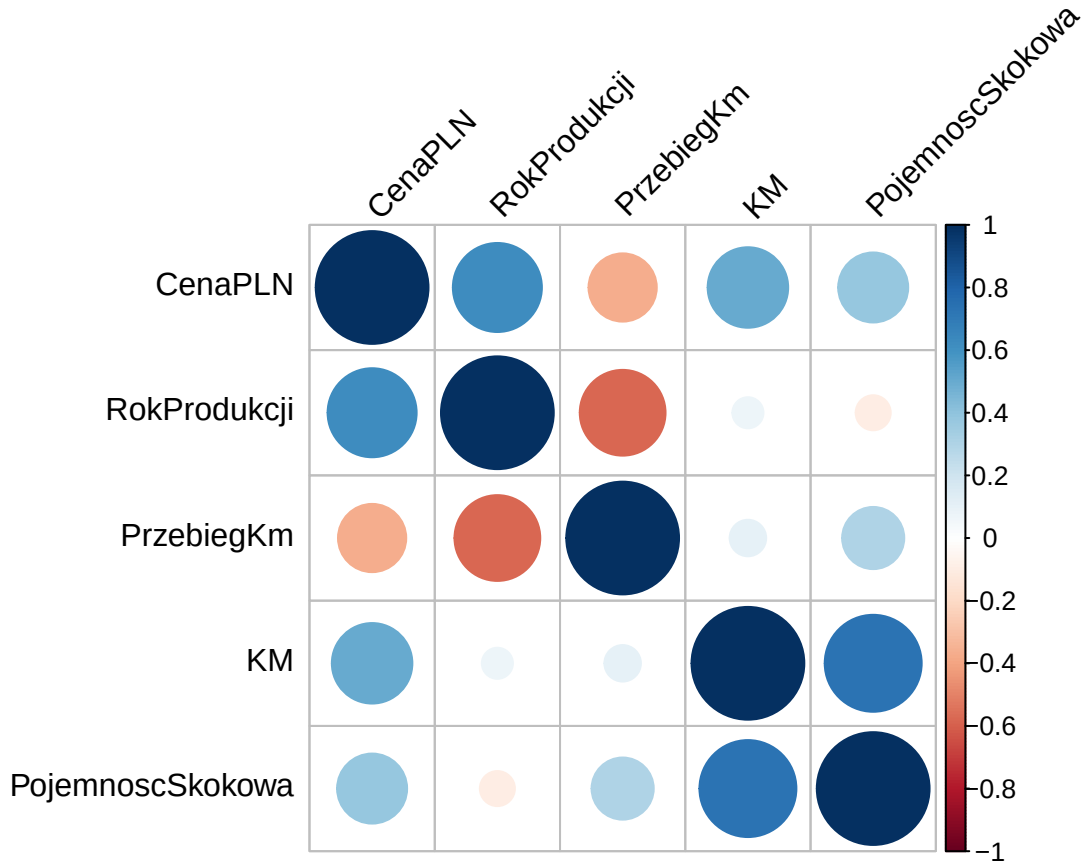

Jak można zaobserwować: - *CenaPLN* skorelowana jest z *RokProdukcji* (silnie), *KM*, *PojemnoscSkokowa* oraz odwrotnie z *PrzebiegKM*,
- *PojemnoscSkokowa* jest silnie skorelowana z ilością *KM* (większa pojemność -> więcej KM), - *PrzebiegKM* jest odwrotnie skorelowany z *RokProdukcji* (starszy samochód -> większy przebieg).

VII - Przedziały ufności

W tej sekcji przedstawione zostaną badania określające przedziały ufności z różnym stopniem 'zaufania'. Oznacza to, że jeśli grupa badana była zgromadzona w sposób losowy to rzeczywisty parametr populacji z z określonym stopniem 'zaufania' znajduje się w tym przedziale.

Zmienna numeryczna

W celu określnenia przedziałów ufności zmiennej numerycznej wybrano cechę *CenaPLN*. Przedział ufności dla średniej:

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_price_mean = mean(database$CenaPLN);
vii_price_sd = sd(database$CenaPLN);
n = length(database$CenaPLN);

# Mean confidence function
mean_confidence <- function(mean, sd, n, confidence_level) {
  alpha = 1 - confidence_level;
  offset = qnorm(1 - alpha / 2) * sd / sqrt(n);
  lower_bound = mean - offset;
  upper_bound = mean + offset;
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
mean_confidence_intervals = sapply(confidence_level, function(conf_level) {
  mean_confidence(vii_price_mean, vii_price_sd, n, conf_level)
});

# Create matrix
mean_confidence_intervals = t(mean_confidence_intervals);
rownames(mean_confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(mean_confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności średniej dla różnych poziomów ufności:");
```

```
## [1] "Przedziały ufności średniej dla różnych poziomów ufności:"
```

```
print(mean_confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9         34413.42        34899.92
## Poziom ufności: 0.95        34366.82        34946.52
## Poziom ufności: 0.99        34275.75        35037.59
```

Przedział ufności dla wariancji:

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);
```

```r
# SD confidence function
sd_confidence <- function(mean, n, confidence_level) {
  alpha = 1 - confidence_level;
  offset = qnorm(1 - alpha / 2) / sqrt(2*n);
  lower_bound = mean / (1 + offset);
  upper_bound = mean / (1 - offset);
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
sd_confidence_intervals = sapply(confidence_level, function(conf_level) {
  sd_confidence(vii_price_mean, n, conf_level);
});

# Create matrix
sd_confidence_intervals = t(sd_confidence_intervals);
rownames(sd_confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(sd_confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności odchylenia standardowego dla różnych poziomów ufności:");
```

```
## [1] "Przedziały ufności odchylenia standardowego dla różnych poziomów ufności:"
```

```r
print(sd_confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9          34455.78         34859.92
## Poziom ufności: 0.95         34417.56         34899.13
## Poziom ufności: 0.99         34343.11         34976.01
```

Przedział ufności dla zmiennej jakościowej (frakcyjna)

Do wyznaczenia przedziału ufności dla zmiennej *PojazdUszkodzony* (rozkład Bernoulliego)

```r
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_positive = sum(database$PojazdUszkodzony == TRUE);
vii_all      = length(database$PojazdUszkodzony);

mean_bool_confidence <- function(m, n, confidence_level) {
  alpha = 1 - confidence_level;
  mn = m / n;
  offset = qnorm(1 - alpha / 2) * sqrt(mn * (1-mn)) / sqrt(n);
  lower_bound = mn - offset;
  upper_bound = mn + offset;
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
confidence_intervals = sapply(confidence_level, function(conf_level) {
  mean_bool_confidence(vii_positive, vii_all, conf_level);
```

```
});

# Create matrix
confidence_intervals = t(confidence_intervals);
rownames(confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności dla frakcji dla różnych poziomów ufności (Udział pojazdów uszkodzonych):");
```

```
## [1] "Przedziały ufności dla frakcji dla różnych poziomów ufności (Udział pojazdów uszkodzonych):"
```

```
print(confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9       0.03528564      0.03839196
## Poziom ufności: 0.95      0.03498810      0.03868950
## Poziom ufności: 0.99      0.03440657      0.03927103
```

IX - Regresja liniowa i inne

Modele dla jednej zmiennej

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "PrzebiegKm"))
model = lm(CenaPLN ~ . , data = ix_database)
ix_sample = ix_database[sample(nrow(ix_database), size=1000),]
plot(CenaPLN ~ PrzebiegKm,  data=ix_sample, col = 'darkcyan')
abline(model, col="red")
```

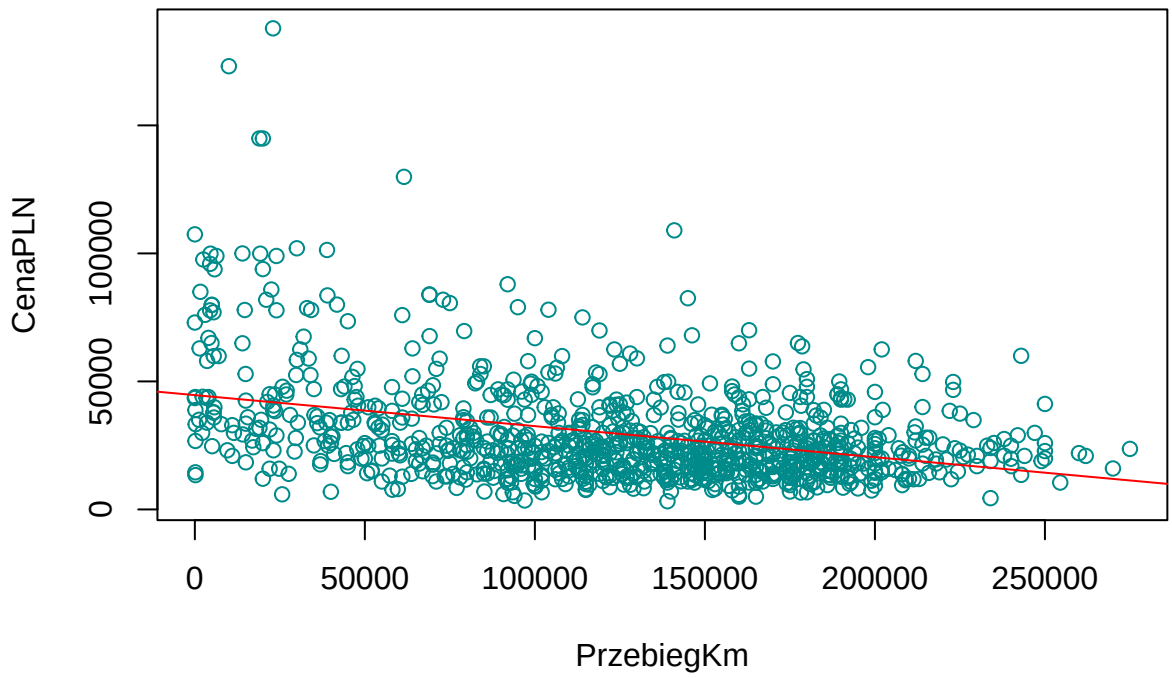


```
summary(model);
```

```
##
## Call:
## lm(formula = CenaPLN ~ ., data = ix_database)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -40733 -11549  -3678   6986 152257
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.465e+04  2.398e+02  186.17   <2e-16 ***
## PrzebiegKm  -1.212e-01  1.706e-03  -71.05   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18550 on 32644 degrees of freedom
## Multiple R-squared:  0.1339, Adjusted R-squared:  0.1339
## F-statistic:  5049 on 1 and 32644 DF,  p-value: < 2.2e-16
```

```
print(model$coefficients);
```

```
##   (Intercept)    PrzebiegKm
## 44651.6424984    -0.1211948
```

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "PojemnoscSkokowa"))
```

```r
model = lm(CenaPLN ~ . , data = ix_database)
ix_sample = ix_database[sample(nrow(ix_database), size=1000),]
plot(CenaPLN ~ PojemnoscSkokowa,  data=ix_sample, col = 'darkcyan')
abline(model, col="red")
```

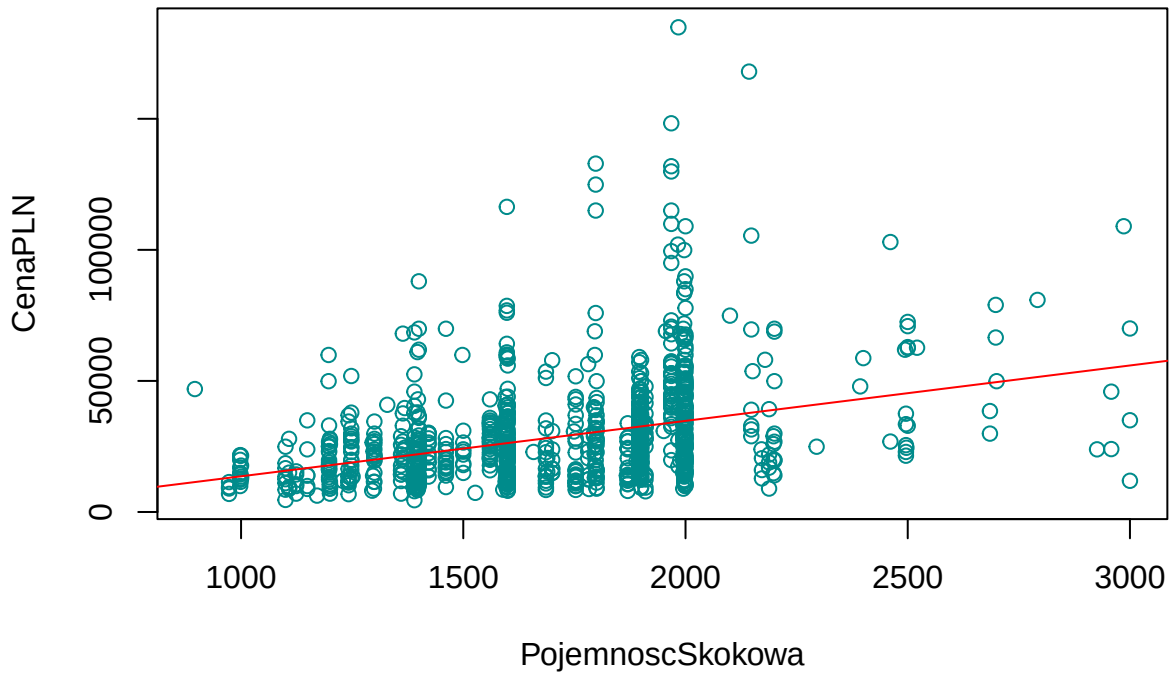


```r
summary(model);
```

```
##
## Call:
## lm(formula = CenaPLN ~ ., data = ix_database)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -106802  -11243   -3490    6365  159245
##
## Coefficients:
##                   Estimate Std. Error t value Pr(>|t|)
## (Intercept)      -7527.2394   497.7274  -15.12   <2e-16 ***
## PojemnoscSkokowa    21.1409     0.2801   75.49   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18390 on 32644 degrees of freedom
## Multiple R-squared:  0.1486, Adjusted R-squared:  0.1486
## F-statistic:  5698 on 1 and 32644 DF,  p-value: < 2.2e-16
```

```
print(model$coefficients);
```

```
##      (Intercept) PojemnoscSkokowa
##      -7527.23942         21.14093
```

Modele dla 2 zmiennych

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "PrzebiegKm", "PojemnoscSkokowa"))
model = lm(CenaPLN ~ . , data = ix_database)

plot3d(model, col='darkcyan', plane.col = 'red')
rglwidget()
```

```
## Warning in snapshot3d(scene = x, width = width, height = height): webshot =
## TRUE requires the webshot2 package and Chrome browser; using rgl.snapshot()
## instead
```

```
## Warning in rgl.snapshot(filename, fmt, top): this build of rgl does not support
## snapshots
```

```
summary(model);
```

```
##
## Call:
## lm(formula = CenaPLN ~ ., data = ix_database)
##
```

```
## Residuals:
##     Min      1Q  Median      3Q     Max
## -156582   -8871   -1542    6472  138780
##
## Coefficients:
##                    Estimate Std. Error  t value Pr(>|t|)
## (Intercept)      -5.437e+02  4.200e+02   -1.294    0.196
## PrzebiegKm       -1.762e-01  1.483e-03 -118.785   <2e-16 ***
## PojemnoscSkokowa  3.000e+01  2.456e-01  122.129   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 15370 on 32643 degrees of freedom
## Multiple R-squared:  0.4056, Adjusted R-squared:  0.4055
## F-statistic: 1.114e+04 on 2 and 32643 DF,  p-value: < 2.2e-16
```

```
print(model$coefficients);
```

```
##      (Intercept)       PrzebiegKm PojemnoscSkokowa
##     -543.7320918       -0.1761712       29.9959737
```

Drzewa decyzyjne

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "RokProdukcji", "PojemnoscSkokowa"))
ix_data_split = initial_split(ix_database, prop = 0.75);
ix_train_data <- training(ix_data_split);
ix_test_data <- testing(ix_data_split);

tree_spec <- decision_tree() %>%
 set_engine("rpart") %>%
 set_mode("regression")

tree_fit <- tree_spec %>%
 fit(CenaPLN ~ ., data = ix_train_data)

predictions <- tree_fit %>%
 predict(ix_test_data) %>%
 pull(.pred)

metrics <- metric_set(rmse, rsq)
model_performance <- ix_test_data %>%
 mutate(predictions = predictions) %>%
 metrics(truth = CenaPLN, estimate = predictions)

print(model_performance)
```

```
## # A tibble: 2 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 rmse    standard   11333.
## 2 rsq     standard       0.665
```

```
rpart.plot(tree_fit$fit, type = 5, extra = 101, under = TRUE, cex = 0.8, box.palette = "auto")
```

```
## Warning: Cannot retrieve the data used to build the model (so cannot determine roundint and is.binary
## To silence this warning:
##     Call rpart.plot with roundint=FALSE,
##     or rebuild the rpart model with model=TRUE.
```