Statystyka matematyczna i ekonometria

Projekt - Auto Sprzedam

Autorzy
Anna Kalitka (255445)
Antoni Bezdzietny (249327)

Projekt zaliczeniowy
Laboratorium, lato 2023/24

I - Opis bazy danych

Wybrana została baza danych **AutoSprzedam**. Baza pochodzi z zasobów ePortalu.

Zawartość bazy danych

Baza danych składa się z 41034 rekordów, zawierających szczegółowe dane dotyczące sprzedaży samochodów m.in.

Kolumna	Typ danych	Opis
NrOferty	int	Numer oferty sprzedaży samochodu.
CenaPLN	string	Cena samochodu wyrażona w polskich złotych (PLN).
KM	int	Liczba koni mechanicznych samochodu.
Marka	string	Marka samochodu.
Model	string	Model samochodu.
LiczbaDrzwi	string	Liczba drzwi w samochodzie.
PojemnoscSkokowa	int	Pojemność skokowa silnika wyrażona w centymetrach sześciennych (cm^3).
PrzebiegKm	int	Przebieg samochodu wyrażony w kilometrach.
RodzajPaliwa	string	Rodzaj paliwa używanego przez samochód (benzyna, diesel, hybryda, elektryczny itp.).
RokProdukcji	int	Rok produkcji samochodu.
Kolor	string	Kolor samochodu.
KrajPochodzenia	string	Kraj pochodzenia samochodu.
PojazdUszkodzony	string	Informacja czy pojazd jest uszkodzony (Tak/Nie).
SkrzyniaBiegow	string	Typ skrzyni biegów w samochodzie (manualna, automatyczna).

Prezentacja bazy danych

```
# Wczytanie bazy danych
database = read.csv("../database/AutoSprzedam.dat", sep = "\t", dec = ',');

cat("Liczba rekordów:", nrow(database), ", liczba kolumn:", ncol(database), "\n")
```

```
## Liczba rekordów: 41034 , liczba kolumn: 14
```

```
N = 5;
cat("-", "Przykład ", N, "pierwszych rekordów.\n")
```

```
## - Przykład  5 pierwszych rekordów.
```

```
head(database, N)
```

```
##   NrOferty CenaPLN  KM         Marka         Model LiczbaDrzwi PojemnoscSkokowa
## 1        1   27900 150          Opel        Vectra         4/5             1900
## 2        2   28000 116        Toyota Corolla Verso         4/5             2000
## 3        3   25500 150         Skoda        Superb         4/5             1781
## 4        4   29900 109 Mercedes-Benz         A 180         2/3             1991
## 5        5   29800 207       Peugeot           607         4/5             2946
##   PrzebiegKm           RodzajPaliwa RokProdukcji              Kolor
## 1      80840 olej napędowy (diesel)         2005    czarny-metallic
## 2     166000 olej napędowy (diesel)         2004              bialy
## 3     112000            benzyna+LPG         2002   bordowy-metallic
## 4      42000 olej napędowy (diesel)         2005           czerwony
## 5     169000                benzyna         2004 granatowy-metallic
##   KrajPochodzenia PojazdUszkodzony SkrzyniaBiegow
## 1          Niemcy              Nie       manualna
## 2          Polska              Nie       manualna
## 3          Polska              Nie       manualna
## 4          Polska              Nie       manualna
## 5         Francja              Nie       manualna
```

```
cat("- ", "Przykład ", N, "ostatnich rekordów.\n")
```

```
## -  Przykład  5 ostatnich rekordów.
```

```
tail(database, N)
```

```
##       NrOferty  CenaPLN  KM         Marka    Model LiczbaDrzwi PojemnoscSkokowa
## 41030    41030 98000.00 220          Opel Insignia         4/5             1998
## 41031    41031 34924.50 184 Mercedes-Benz    S 400         4/5             3996
## 41032    41032 41175.09  70       Peugeot      308         2/3             1397
## 41033    41033 47900.00 115          Ford    C-MAX         4/5             1560
## 41034    41034 14200.00  90          Ford   Mondeo         4/5             1998
##       PrzebiegKm           RodzajPaliwa RokProdukcji              Kolor
## 41030      25500                benzyna         2010 grafitowy-metallic
## 41031     162000 olej napędowy (diesel)         2001   srebrny-metallic
## 41032       9289                benzyna         2010   srebrny-metallic
## 41033      45000 olej napędowy (diesel)         2010    czarny-metallic
## 41034     191024 olej napędowy (diesel)         2003    czarny-metallic
##       KrajPochodzenia PojazdUszkodzony SkrzyniaBiegow
## 41030          Polska              Nie       manualna
## 41031          Czechy              Nie   automatyczna
## 41032          Niemcy              Nie       manualna
```

```
## 41033          Belgia              Nie       manualna
## 41034          Niemcy              Nie       manualna
```

Przygotowanie bazy danych

Przed przejściem do dalszej pracy z bazą danych postanowiono wprowadzenie zmian w jej strukturze, których celem jest uproszczenie przyszłych prac z danymi.

Pole - *SkrzyniaBiegow*

W bazie występują 3 rodzaje typów skrzyni biegów: *półautomatyczna/sekwencyjna*, *manualna* oraz *automatyczna*. Udział typu *półautomatyczna/sekwencyjna* w całej bazie wynosi 1,5%.

W związku z niewielkim udziałem ze skrzynią *półautomatyczna/sekwencyjna*, typ ten został usunięty z bazy. Dzięki czemu możliwe jest przekształcenie kolumny *SkrzyniaBiegow* (char), na *SkrzyniaBiegowManualna* (bool).

```
gear_box_summary = database %>% group_by(database$SkrzyniaBiegow) %>% summarise(liczba = n());

gear_box_summary
```

```
## # A tibble: 3 x 2
##   `database$SkrzyniaBiegow`   liczba
##   <chr>                        <int>
## 1 automatyczna                  6941
## 2 manualna                     34030
## 3 półautomatyczna/sekwencyjna     63
```

```
cat("Udział pojazdów ze skrzynią biegów typu 'półautomatyczna/sekwencyjna'",
    sum(gear_box_summary[3,2])/sum(gear_box_summary[,2])*100, "%.");
```

```
## Udział pojazdów ze skrzynią biegów typu 'półautomatyczna/sekwencyjna' 0.1535312 %.
```

```
# Remove cars with database$SkrzyniaBiegow == 'półautomatyczna/sekwencyjna'
database = database[database$SkrzyniaBiegow != "półautomatyczna/sekwencyjna",];

# Cast to logical value
database$SkrzyniaBiegow = database$SkrzyniaBiegow == "manualna";
colnames(database)[14] = "SkrzyniaBiegowManualna";
```

Pole *PojazdUszkodzony*

Domyślnym typem danych dla pola *PojazdUszkodzony* jest (char). Zmienna jest typem logicznym (TAK/NIE). W związku z powyższym kolumna *PojazdUszkodzony* została przekształcona to typu *bool*.

```
database$PojazdUszkodzony = database$PojazdUszkodzony == "Tak";
```

Pole *Liczba drzwi*

W bazie występują pojazdy tylko i wyłącznie z dwoma liczbami drzwi *2/3* oraz *4/5*. W związku z powyższym można analogicznie przekształcić typ danych na typ *bool*.

```
database$LiczbaDrzwi = database$LiczbaDrzwi == "4/5";
colnames(database)[6] = "LiczbaDrzwi4/5"
```

Prezentacja bazy danych - po wprowadzonych zmianach

```
N = 5;
cat("-", "Przykład ", N, "pierwszych rekordów.\n")
```

```
## - Przykład  5 pierwszych rekordów.
```

```
head(database, N)
```

```
##   NrOferty CenaPLN  KM         Marka         Model LiczbaDrzwi4/5
## 1        1   27900 150          Opel        Vectra           TRUE
## 2        2   28000 116        Toyota Corolla Verso           TRUE
## 3        3   25500 150         Skoda        Superb           TRUE
## 4        4   29900 109 Mercedes-Benz         A 180          FALSE
## 5        5   29800 207       Peugeot           607           TRUE
##   PojemnoscSkokowa PrzebiegKm           RodzajPaliwa RokProdukcji
## 1             1900      80840 olej napędowy (diesel)         2005
## 2             2000     166000 olej napędowy (diesel)         2004
## 3             1781     112000            benzyna+LPG         2002
## 4             1991      42000 olej napędowy (diesel)         2005
## 5             2946     169000                benzyna         2004
##               Kolor KrajPochodzenia PojazdUszkodzony SkrzyniaBiegowManualna
## 1    czarny-metallic          Niemcy            FALSE                   TRUE
## 2              bialy          Polska            FALSE                   TRUE
## 3   bordowy-metallic          Polska            FALSE                   TRUE
## 4           czerwony          Polska            FALSE                   TRUE
## 5 granatowy-metallic         Francja            FALSE                   TRUE
```

```
cat("- ", "Przykład ", N, "ostatnich rekordów.\n")
```

```
## -  Przykład  5 ostatnich rekordów.
```

```
tail(database, N)
```

```
##       NrOferty  CenaPLN  KM         Marka    Model LiczbaDrzwi4/5
## 41030    41030 98000.00 220          Opel Insignia           TRUE
## 41031    41031 34924.50 184 Mercedes-Benz    S 400           TRUE
## 41032    41032 41175.09  70       Peugeot      308          FALSE
## 41033    41033 47900.00 115          Ford    C-MAX           TRUE
## 41034    41034 14200.00  90          Ford   Mondeo           TRUE
##       PojemnoscSkokowa PrzebiegKm           RodzajPaliwa RokProdukcji
## 41030             1998      25500                benzyna         2010
## 41031             3996     162000 olej napędowy (diesel)         2001
## 41032             1397       9289                benzyna         2010
## 41033             1560      45000 olej napędowy (diesel)         2010
## 41034             1998     191024 olej napędowy (diesel)         2003
##                    Kolor KrajPochodzenia PojazdUszkodzony
## 41030 grafitowy-metallic          Polska            FALSE
## 41031   srebrny-metallic          Czechy            FALSE
## 41032   srebrny-metallic          Niemcy            FALSE
## 41033    czarny-metallic          Belgia            FALSE
## 41034    czarny-metallic          Niemcy            FALSE
##       SkrzyniaBiegowManualna
## 41030                   TRUE
## 41031                  FALSE
## 41032                   TRUE
```

```
## 41033                    TRUE
## 41034                    TRUE
```

II - Wyznaczenie podstawowych statystyk

W tej sekcji przedstawione zostaną podstawowe statystyki dla wybranych zmiennych.

Statystyki dla zmiennych nuemrycznych

```
numerical_database = data.frame(database$CenaPLN,
                                database$KM,
                                database$PojemnoscSkokowa,
                                database$PrzebiegKm,
                                database$RokProdukcji);
numerical_statistics = data.frame(do.call(cbind, lapply(numerical_database, summary)));
numerical_statistics[nrow(numerical_statistics)+1,] = sapply(numerical_database, var);
numerical_statistics[nrow(numerical_statistics)+1,] = sapply(numerical_database, sd);
row.names(numerical_statistics)[7:8] <- c("Var","Sd");
numerical_statistics
```

```
##         database.CenaPLN database.KM database.PojemnoscSkokowa
## Min.        1.000000e+03     1.00000                    13.0000
## 1st Qu.     1.720000e+04    83.00000                  1560.0000
## Median      2.600000e+04   110.00000                  1896.0000
## Mean        4.084835e+04   121.00517                  1916.8589
## 3rd Qu.     4.190000e+04   140.00000                  1998.0000
## Max.        1.788000e+06  1400.00000                  7300.0000
## Var         2.636581e+09  3589.98079                415825.4410
## Sd          5.134764e+04    59.91645                   644.8453
##         database.PrzebiegKm database.RokProdukcji
## Min.                    1.0           2001.000000
## 1st Qu.             80000.0           2003.000000
## Median             131000.0           2005.000000
## Mean               125329.7           2005.289864
## 3rd Qu.            170361.0           2007.000000
## Max.              2600000.0           2011.000000
## Var            5110148687.7              7.805945
## Sd                   71485.3              2.793912
```

Statystyki dla zmiennych dwumianowych

```
logical_database = data.frame(database$`LiczbaDrzwi4/5`,
                              database$PojazdUszkodzony,
                              database$SkrzyniaBiegowManualna);

logical_statistics = data.frame(do.call(cbind, lapply(logical_database, summary)))[2:3,];
logical_statistics = data.frame(Class = c("False", "True"),
                                PojazdUszkodzony = as.double(logical_statistics$database.PojazdUszkodzon
                                SkrzyniaBiegowManualna = as.double(logical_statistics$database.Skrzynial
                                LiczbaDrzwi4_5 = as.double(logical_statistics$database..LiczbaDrzwi4.5.)
logical_statistics
```

```
##   Class PojazdUszkodzony SkrzyniaBiegowManualna LiczbaDrzwi4_5
```

```
## 1 False            39497                  6941           5301
## 2  True             1474                 34030          35670
```

Statystyki dla pozostałych zmiennych (jakościowych)

```
quality_database = data.frame(database$Marka,
                              database$RodzajPaliwa,
                              database$Kolor,
                              database$KrajPochodzenia);

sapply(quality_database, function (x){
  round(sort(table(x), decreasing = TRUE) / nrow(quality_database) , 3)})
```

```
## $database.Marka
## x
##    Volkswagen          Ford          Opel       Renault          Audi
##         0.151         0.132         0.122         0.115         0.091
##       Peugeot         Skoda        Toyota Mercedes-Benz           BMW
##         0.078         0.072         0.066         0.064         0.062
##          Fiat
##         0.047
##
## $database.RodzajPaliwa
## x
## olej napędowy (diesel)                benzyna             benzyna+LPG
##                  0.680                  0.297                  0.022
##                hybryda             benzyna+CNG       napęd elektryczny
##                  0.001                  0.001                  0.000
##
## $database.Kolor
## x
##   srebrny-metallic    czarny-metallic niebieski-metallic     szary-metallic
##              0.252              0.191              0.070              0.068
## grafitowy-metallic granatowy-metallic              bialy   zielony-metallic
##              0.057              0.056              0.053              0.033
##           czerwony             czarny          niebieski          granatowy
##              0.031              0.029              0.027              0.025
##     zloty-metallic            srebrny   bordowy-metallic  czerwony-metallic
##              0.017              0.012              0.012              0.011
##    bezowy-metallic   brazowy-metallic     bialy-metallic             zolty
##              0.009              0.009              0.007              0.005
##            zielony              szary  wisniowy-metallic fioletowy-metallic
##              0.005              0.004              0.004              0.003
##          grafitowy pomaranczowy-metal            bordowy             bezowy
##              0.003              0.002              0.002              0.001
##              zloty     zolty-metallic          fioletowy            brazowy
##              0.001              0.001              0.000              0.000
##       pomaranczowy            wisniowy    rozowy-metallic             rozowy
##              0.000              0.000              0.000              0.000
##
## $database.KrajPochodzenia
## x
##            Niemcy            Polska           Francja            Czechy
##             0.398             0.298             0.092             0.063
```

```
##             Belgia             Wlochy           Holandia            Austria
##              0.052              0.024              0.020              0.014
## Stany Zjednoczone          Szwajcaria    Wielka Brytania         Luksemburg
##              0.014              0.008              0.005              0.004
##             Dania          Hiszpania            Szwecja            Kanada
##              0.003              0.003              0.001              0.001
##          Slowacja           Irlandia           Norwegia           Estonia
##              0.000              0.000              0.000              0.000
##           Rumunia             Wegry             Grecja          Islandia
##              0.000              0.000              0.000              0.000
##             Rosja
##              0.000
```

III - Graficzna prezentacja danych

Wykresy dla zmiennych nuemrycznych

```
sapply(numerical_database, draw_numerical);
```

```
## $database.CenaPLN
```

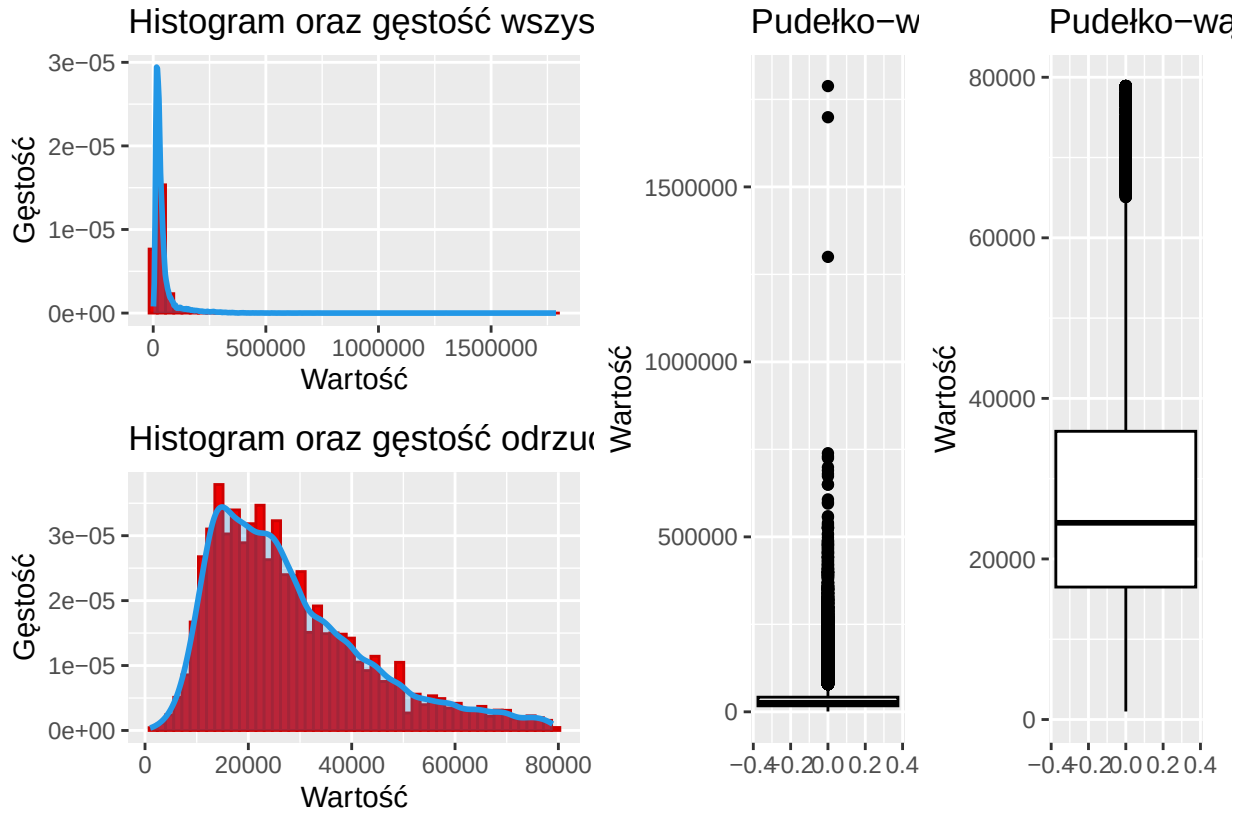


```
##
## $database.KM
```

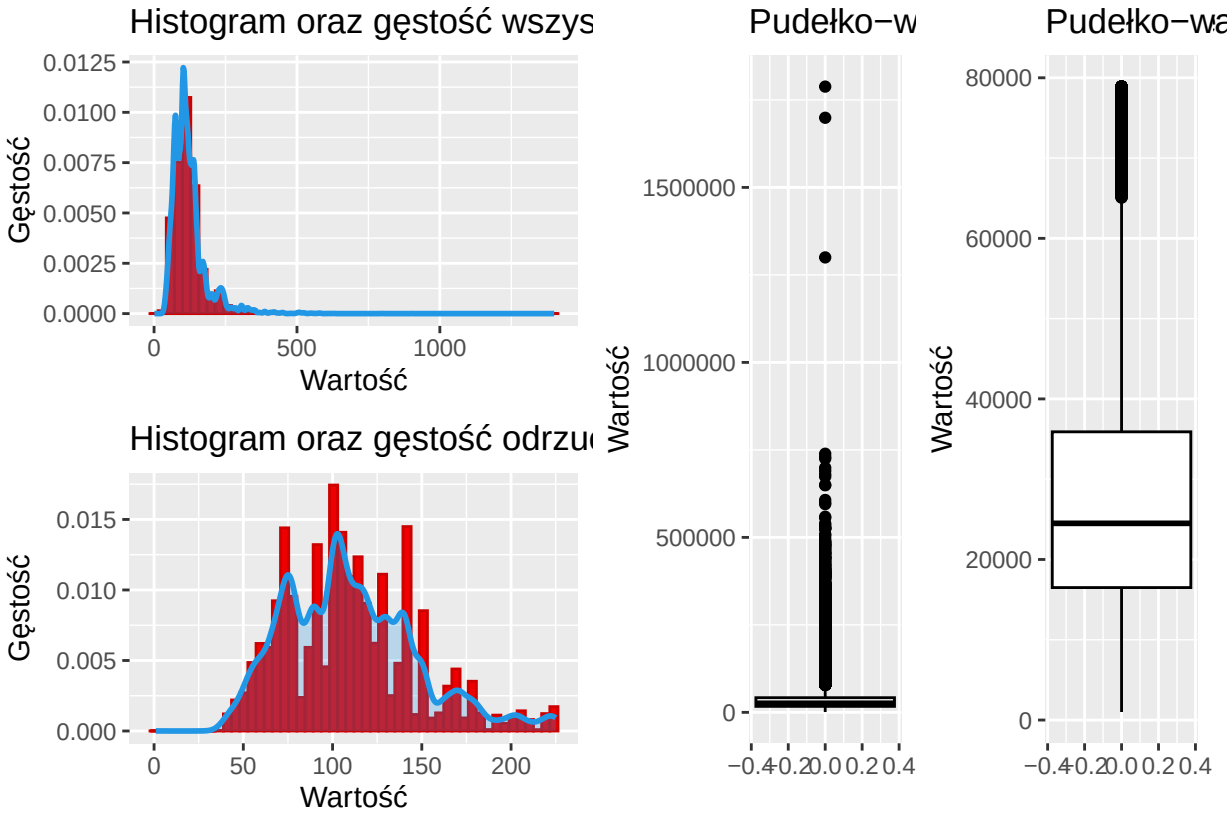


```
##
## $database.PojemnoscSkokowa
```

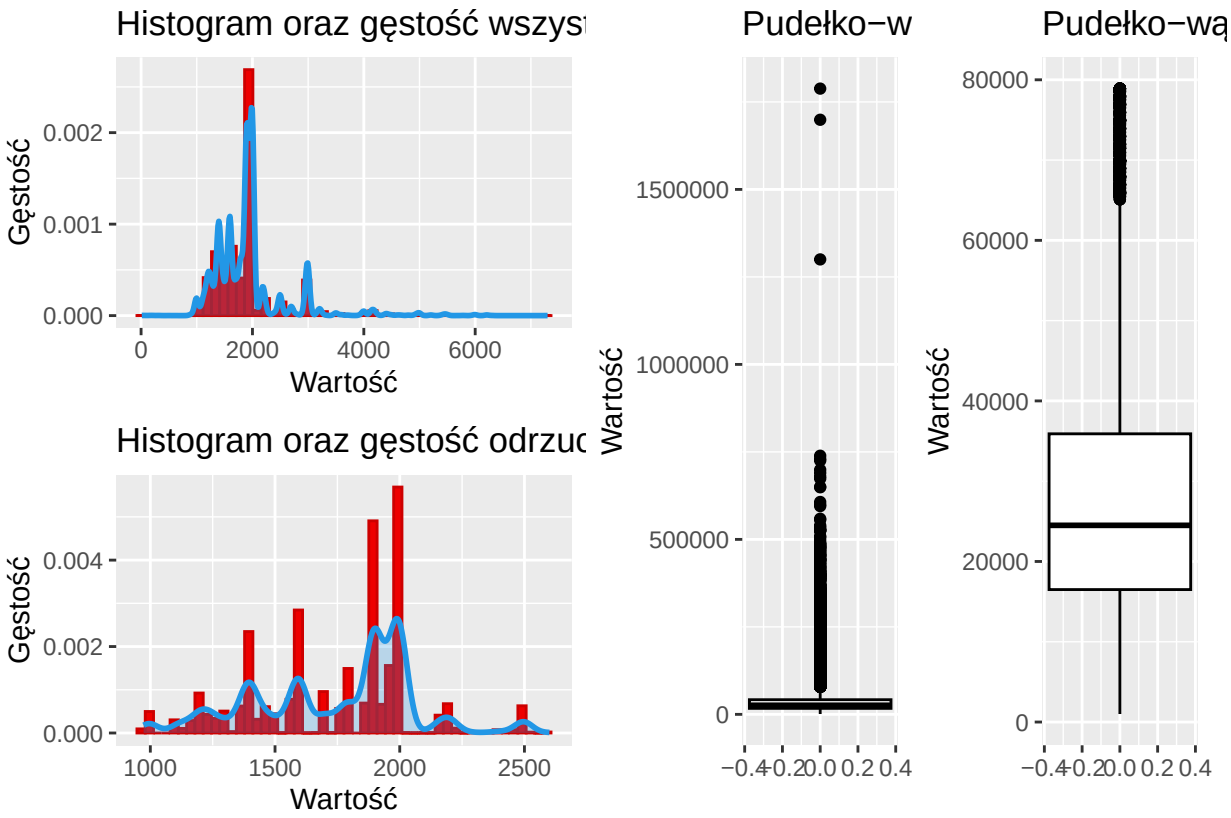


```
##
## $database.PrzebiegKm
```

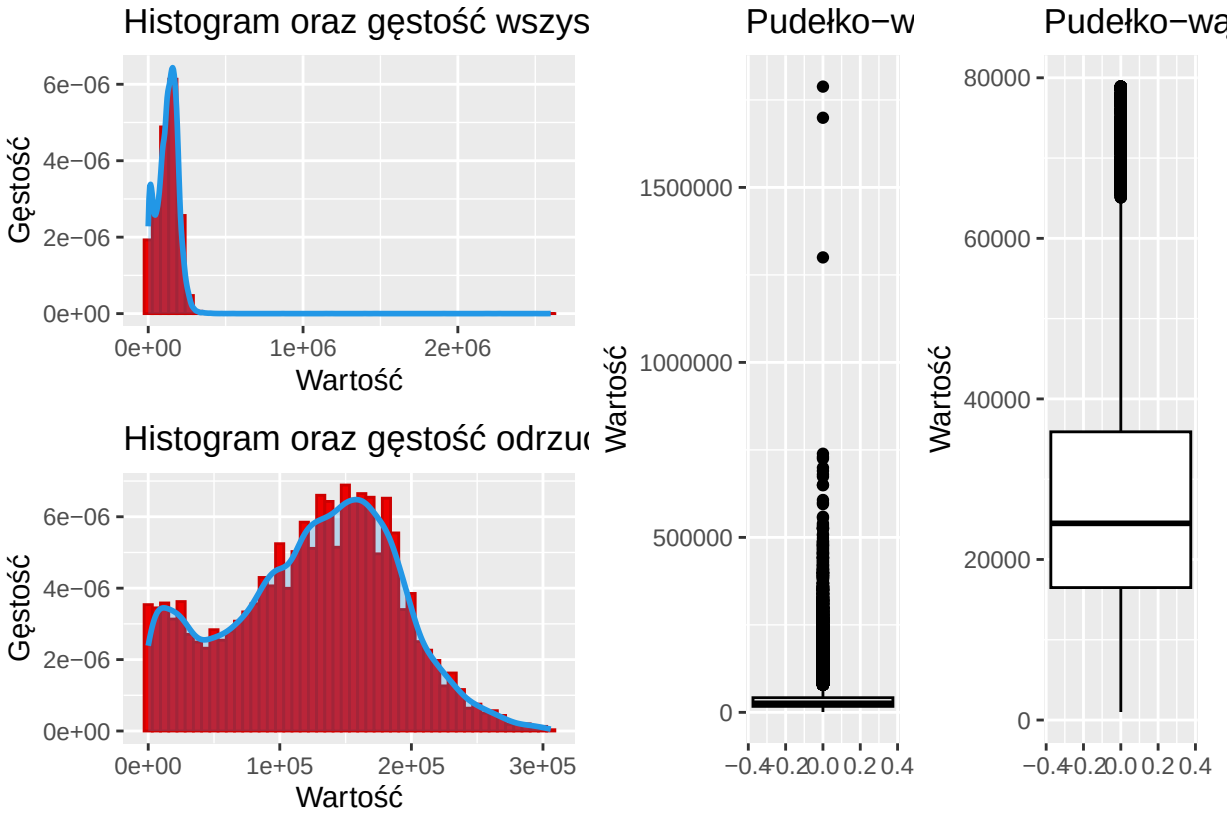


```
##
## $database.RokProdukcji
```

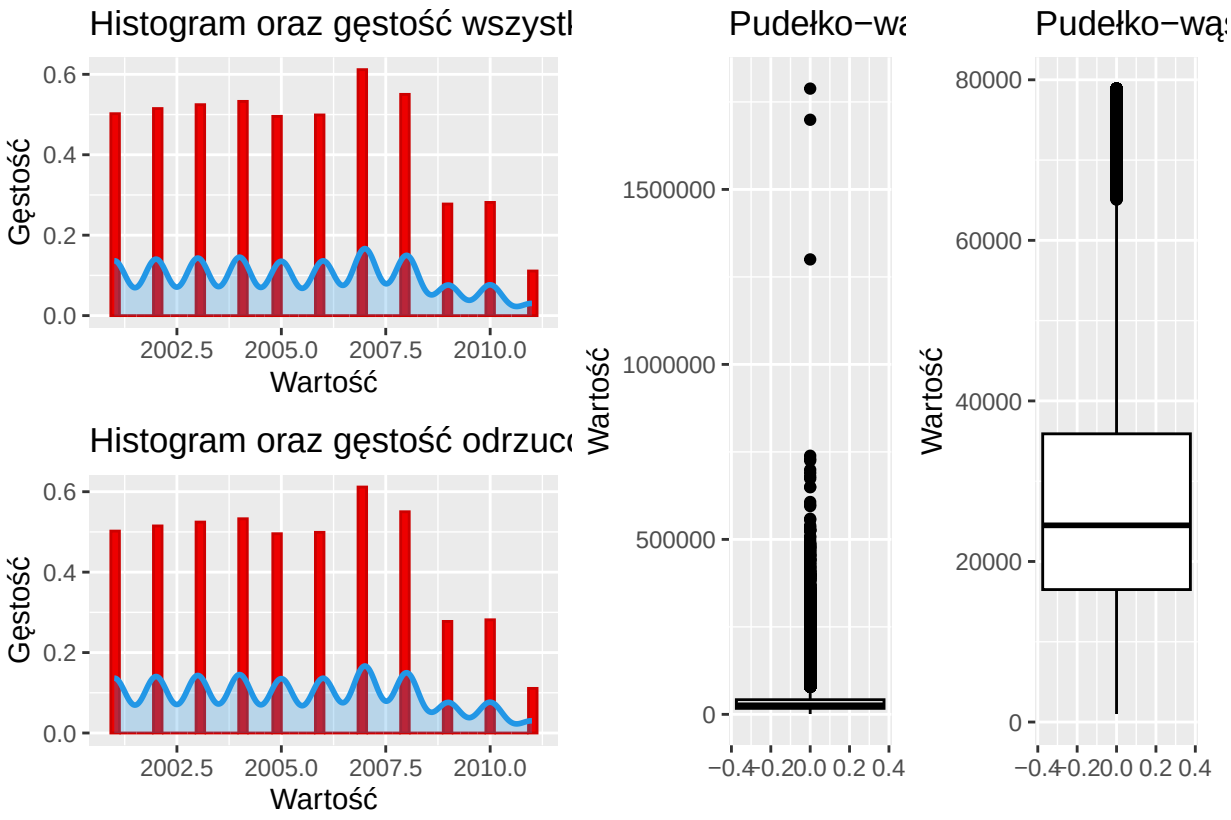

Statystyki dla zmiennych jakościowych

```
ggplot(logical_statistics, aes(x="", y=PojazdUszkodzony, fill=Class)) +
  geom_bar(stat="identity", width=1, color="white") +
  coord_polar("y", start=0) +
  theme_void() + ggtitle("Pojazd uszkodzony");
```

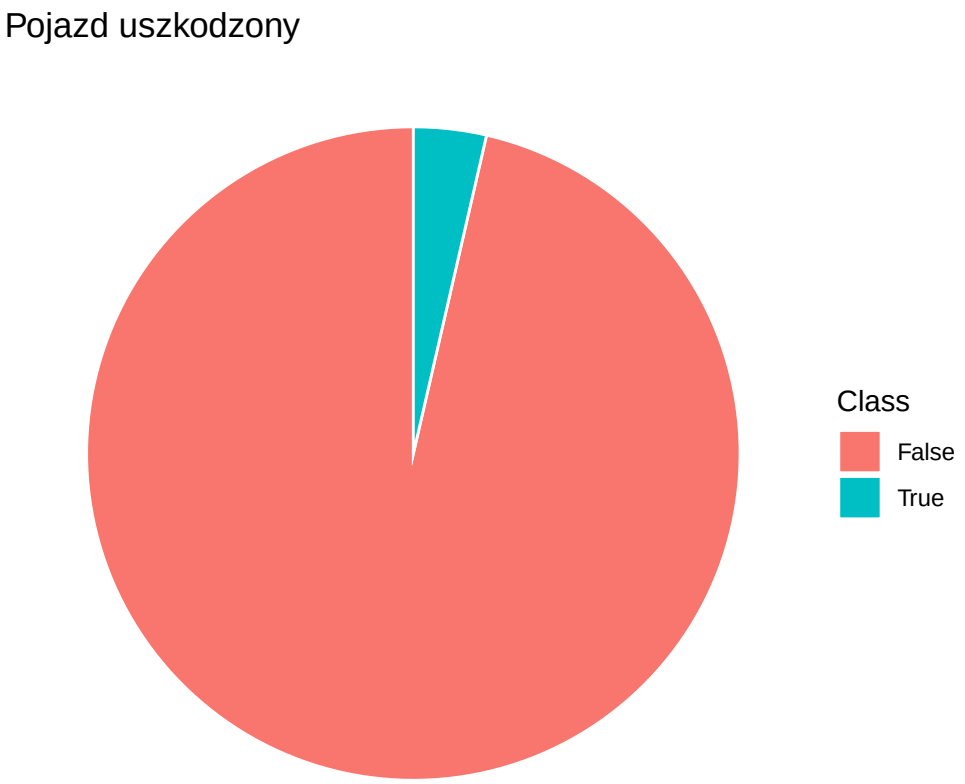


```
ggplot(logical_statistics, aes(x="", y=SkrzyniaBiegowManualna, fill=Class)) +
  geom_bar(stat="identity", width=1, color="white") +
  coord_polar("y", start=0) +
  theme_void() + ggtitle("Skrzynia manualna")
```

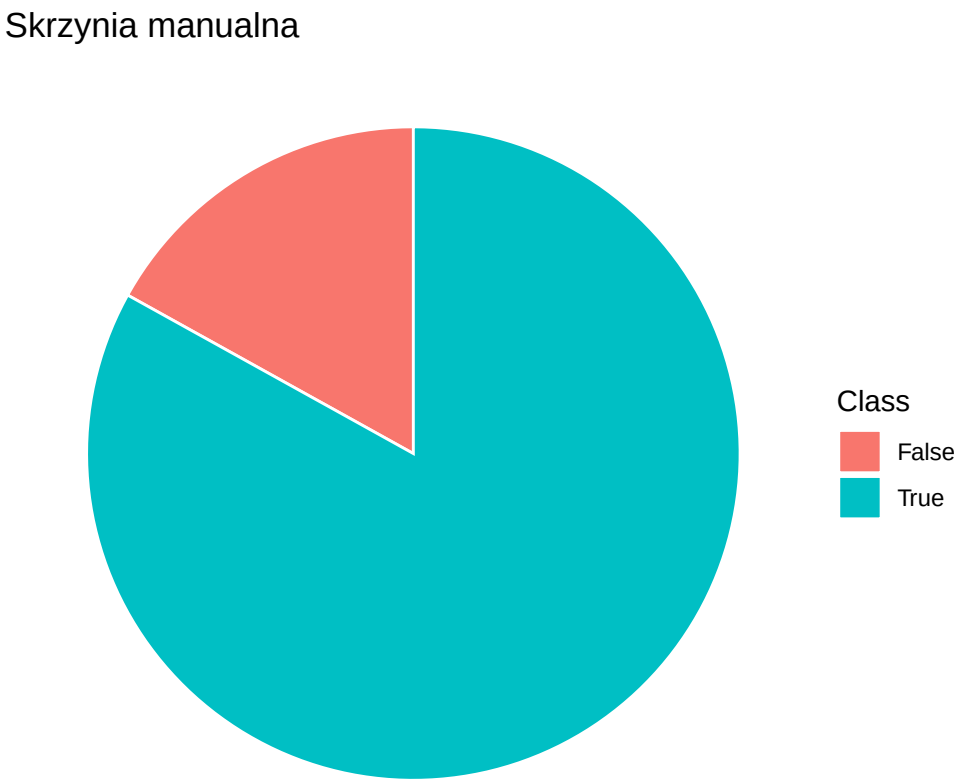


```
ggplot(logical_statistics, aes(x="", y=LiczbaDrzwi4_5, fill=Class)) +
  geom_bar(stat="identity", width=1, color="white") +
  coord_polar("y", start=0) +
  theme_void() + ggtitle("Liczba drzwi 4/5")
```

Liczba drzwi 4/5

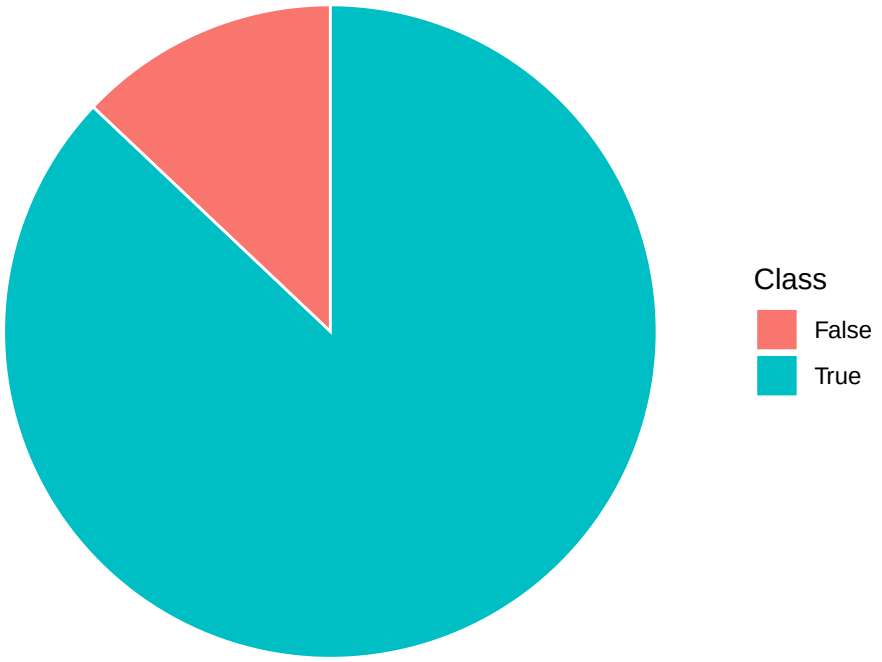


```
wzg_marka = database %>% group_by(Marka) %>% summarise(liczbaSprzedanych = n(),
                                                       sredniaCena = mean(CenaPLN),
                                                       medianaCena = median(CenaPLN));

ggplot(wzg_marka, aes(y=Marka, x=sredniaCena)) +
    geom_bar(position="dodge", stat="identity", fill="orange")+
    ggtitle("Średnia cena sprzedaży dla marki")
```

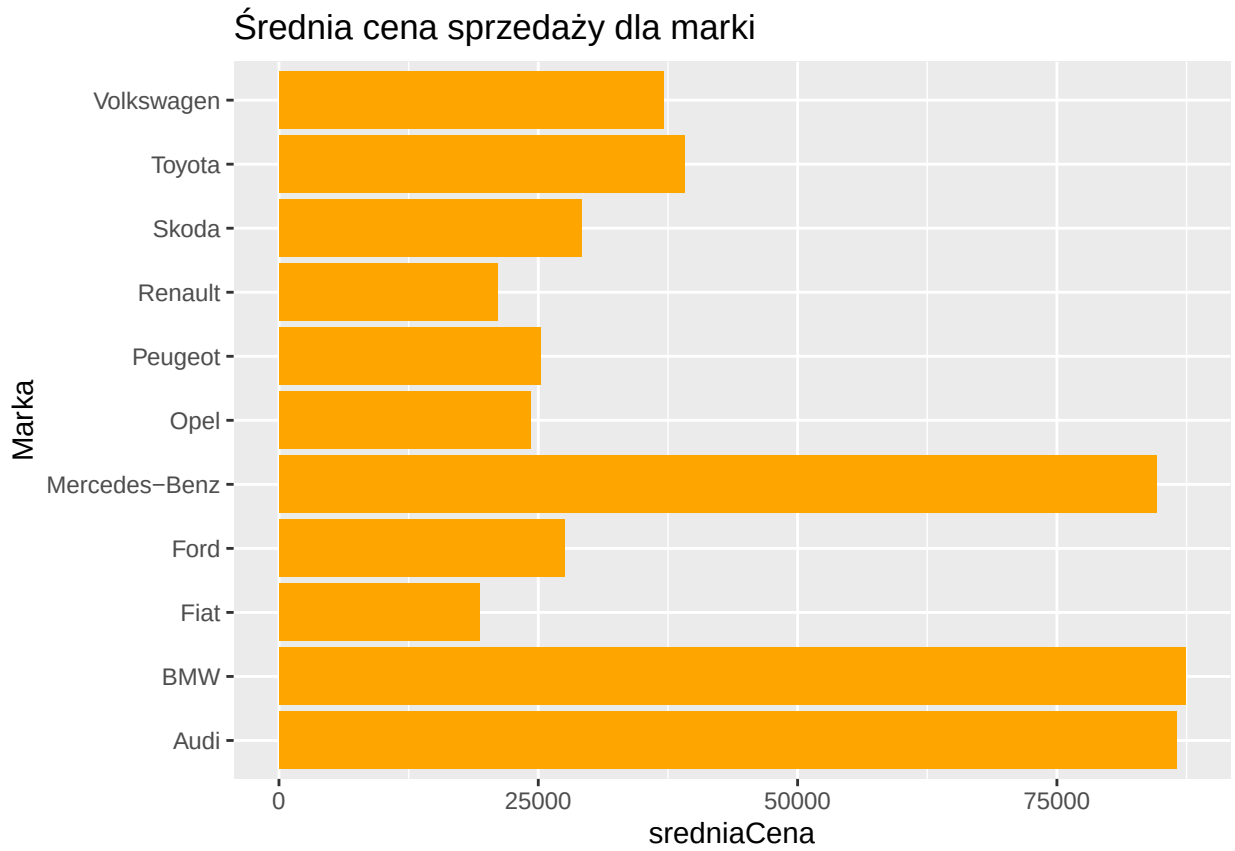


```
ggplot(wzg_marka, aes(y=Marka, x=liczbaSprzedanych)) +
    geom_bar(position="dodge", stat="identity", fill="lightblue")+
    ggtitle("Liczba sprzedanych pojazdów")
```

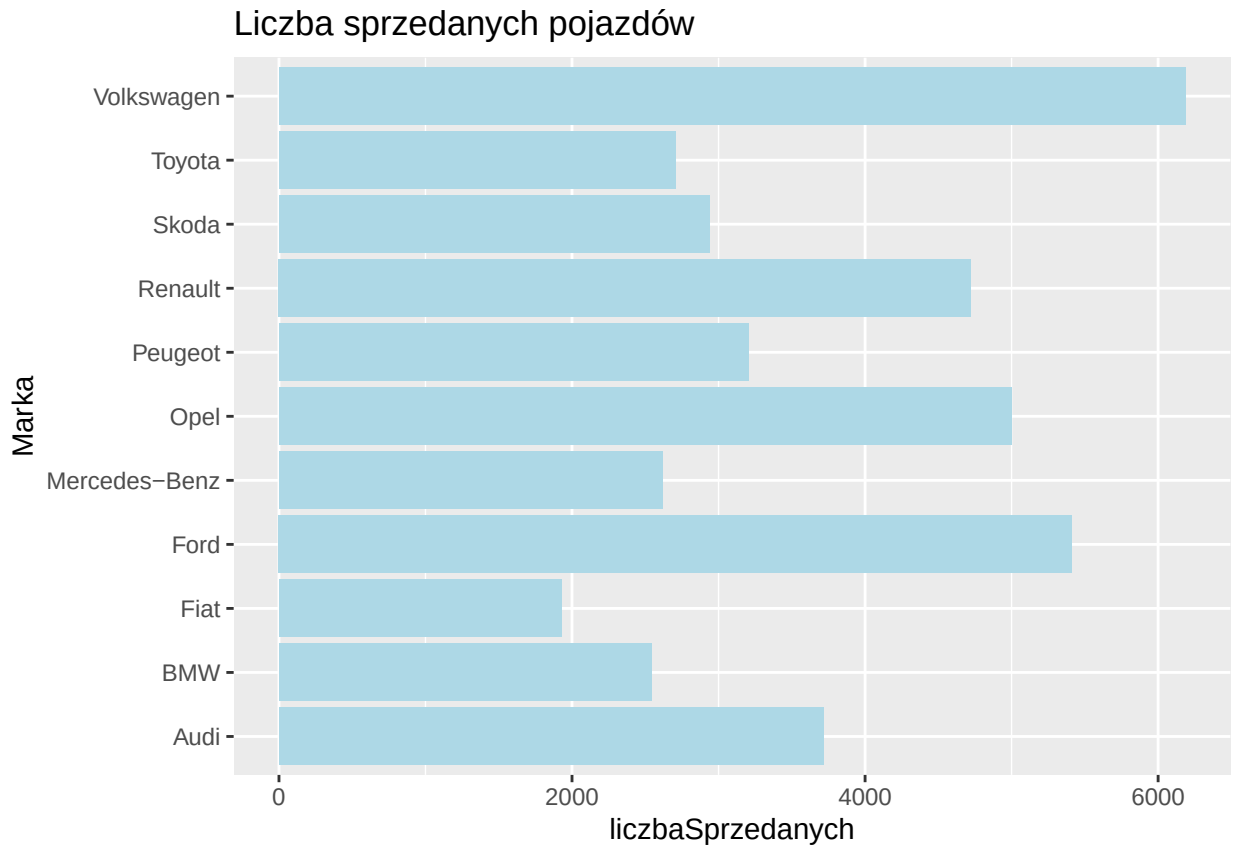


```
fuelType = database %>% group_by(database$RodzajPaliwa) %>% summarise(liczba = n());
colnames(fuelType) = c("FuelType", "Count");
fuelType = fuelType[order(fuelType$Count, decreasing = TRUE),]
fuelType
```

```
## # A tibble: 6 x 2
##   FuelType               Count
##   <chr>                  <int>
## 1 olej napędowy (diesel) 27865
## 2 benzyna                12161
## 3 benzyna+LPG              886
## 4 hybryda                   25
## 5 benzyna+CNG               23
## 6 napęd elektryczny         11
```

```
ggplot(fuelType, aes(x="", y=Count, fill=FuelType)) +
  geom_bar(stat="identity", width=1, color="white") +
  coord_polar("y", start=0) + theme_void();
```

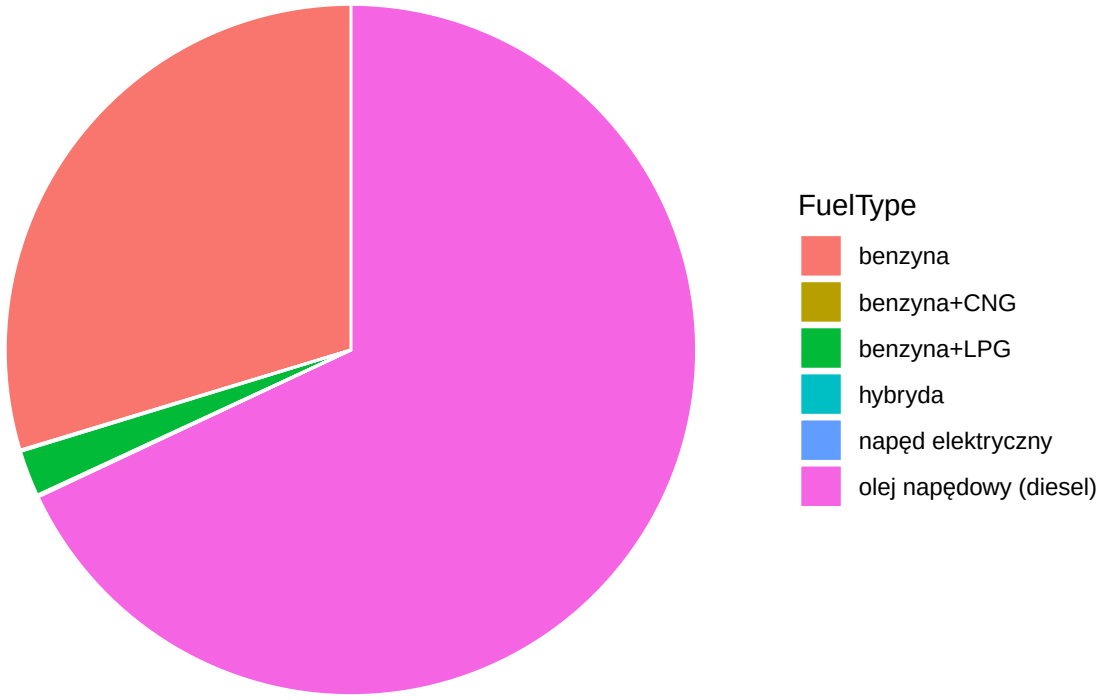

IV - Obserwacje odstające

Obserwacja odstająca, element odstający – obserwacja relatywnie odległa od pozostałych elementów próby. Innymi słowy, posiadająca nietypową wartość zmiennej niezależnej (objaśniającej) lub nietypowe wartości obydwu zmiennych – zależnej (objaśnianej) i objaśniającej (objaśniających w analizie regresji wielokrotnej).

Redukcja danych odstających zgodnie z regułą 3 sigma (*CenaPLN*)

Redukcja danych zgodnie z regułą 3 sigma.

Identyfikacja danych odstających za pomocą reguły trzech sigm:

1. Obliczenie średniej (μ): Najpierw oblicza się średnią dla danego zbioru danych.
2. Obliczenie odchylenia standardowego (σ): Następnie oblicza się odchylenie standardowe, które mierzy, jak bardzo dane rozpraszają się wokół średniej.
3. Ustalenie zakresu trzech sigm: Wartości, które znajdują się poza zakresem trzech sigm ($\mu \pm 3\sigma$), są uznawane za dane odstające.

```
iv_sigma_mean_price = mean(database$CenaPLN);
iv_sigma_sd_price   = sd(database$CenaPLN);

iv_sigma_lower_bound <- iv_sigma_mean_price - 3 * iv_sigma_sd_price;
iv_sigma_upper_bound <- iv_sigma_mean_price + 3 * iv_sigma_sd_price;

cat("Wyznacznowe granice metodą 3 sigma: \n")
```

```
## Wyznacznowe granice metodą 3 sigma:
```

```
cat("Dolna granica ", iv_sigma_lower_bound, ", górna granica ", iv_sigma_upper_bound, "\n");
```

```
## Dolna granica  -113194.6 , górna granica  194891.3
```

```
iv_n_sigma_outlier = sum(database$CenaPLN >= iv_sigma_upper_bound |
                         database$CenaPLN <= iv_sigma_lower_bound)

cat("Ilość elementów odstających zgodnie z regułą 3 sigma dla CenaPLN n =", iv_n_sigma_outlier, "\n");
```

```
## Ilość elementów odstających zgodnie z regułą 3 sigma dla CenaPLN n = 1032
```

Redukcja danych odstających regułą odstępu międzykwartylowgo (*PrzebiegKM*)

Metoda redukcji, polega na wykrywaniu i usuwaniu wartości odstających z zestawu danych. Metoda ta opiera się na kwartylach i rozstępie międzykwartylowym.

1. Wyznaczenie *Q1* (pierwszy kwartyl) oraz *Q3* (trzeci kwartyl)
2. Wyznaczenie odstępu międzykwartylowego $IQR = Q3 - Q1$
3. Wyznaczenie dolnej $Q1 - 1.5 \times IQR$ oraz górnej $Q1 + 1.5 \times IQR$ granicy.

```
iv_Q1 = quantile(database$PrzebiegKm, 0.25);
iv_Q3 = quantile(database$PrzebiegKm, 0.75);
iv_IQR = iv_Q3-iv_Q1;
iv_lower_bound = iv_Q1 - 1.5*iv_IQR #mniejsze niż
iv_upper_bound = iv_Q3 + 1.5*iv_IQR #większe niż

cat("Wyznacznowe granice metodą odstępu międzykwartylowgo  \n")
```

```
## Wyznacznowe granice metodą odstępu międzykwartylowgo
```

```
cat("Dolna granica ", iv_lower_bound, ", górna granica ", iv_upper_bound, "\n");
```

```
## Dolna granica  -55541.5 , górna granica  305902.5
```

```
iv_n_outlier = sum(database$PrzebiegKm >= iv_upper_bound |
                   database$PrzebiegKm <= iv_lower_bound)

cat("Ilość elementów odstających zgodnie z regułą odstępu międzykwartylowego PrzebiegKm n =", iv_n_outli
```

```
## Ilość elementów odstających zgodnie z regułą odstępu międzykwartylowego PrzebiegKm n = 137
```

V - Wyznaczanie prawdopodobieństw dla zmiennej

Rozkłady dyskretne

Dwumianowy

```
#Generowanie próbki
set.seed(42)
N <- 1000
n <- 20
p <- 0.4
X <- rbinom(N, n, p)
```

```r
#Prawdopodobieństwa
pbinom(8, n, p) - pbinom(7, n, p) # P(X=8) p. punktowe
```

```
## [1] 0.1797058
```

```r
pbinom(10, n, p) # P(X<=10) p. przedziałowe
```

```
## [1] 0.8724788
```

```r
#Wykres gęstości
a <- seq(0, n, by = 1)
b <- dbinom(a, n, p)
plot(a,b, type="h")
```

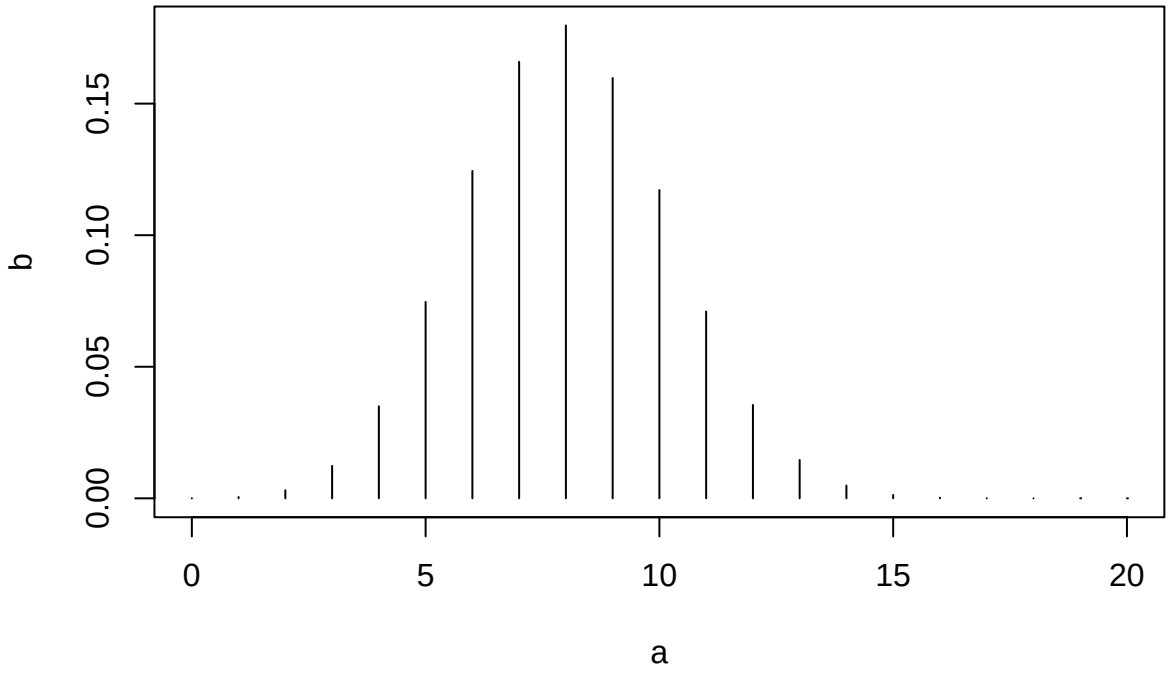


```r
#Wykres dystrybuanty
a <- seq(0, n, by = 1)
b <- pbinom(a, n, p)
plot(a,b)
```

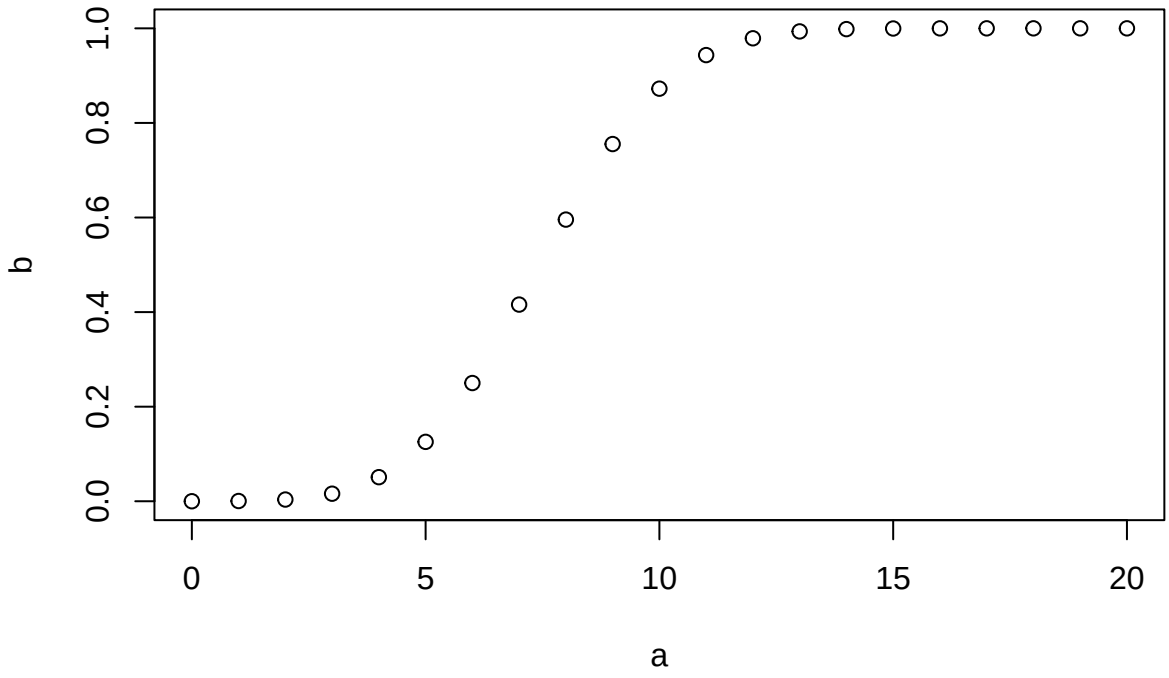

Rozkład Poissona

```
#Generowanie próbki
N <- 1000
lambda <- 200
X <- rpois(N, lambda)

#Prawdopodobieństwa
ppois(190, lambda) - ppois(189, lambda) # P(X=190)
```

```
## [1] 0.02243432
```

```
ppois(190, lambda) #(P<=190)
```

```
## [1] 0.2529326
```

```
#Wykres gęstości
a <- seq(min(X), max(X), by = 1)
b <- dpois(a, lambda)
plot(a,b, type="h")
```

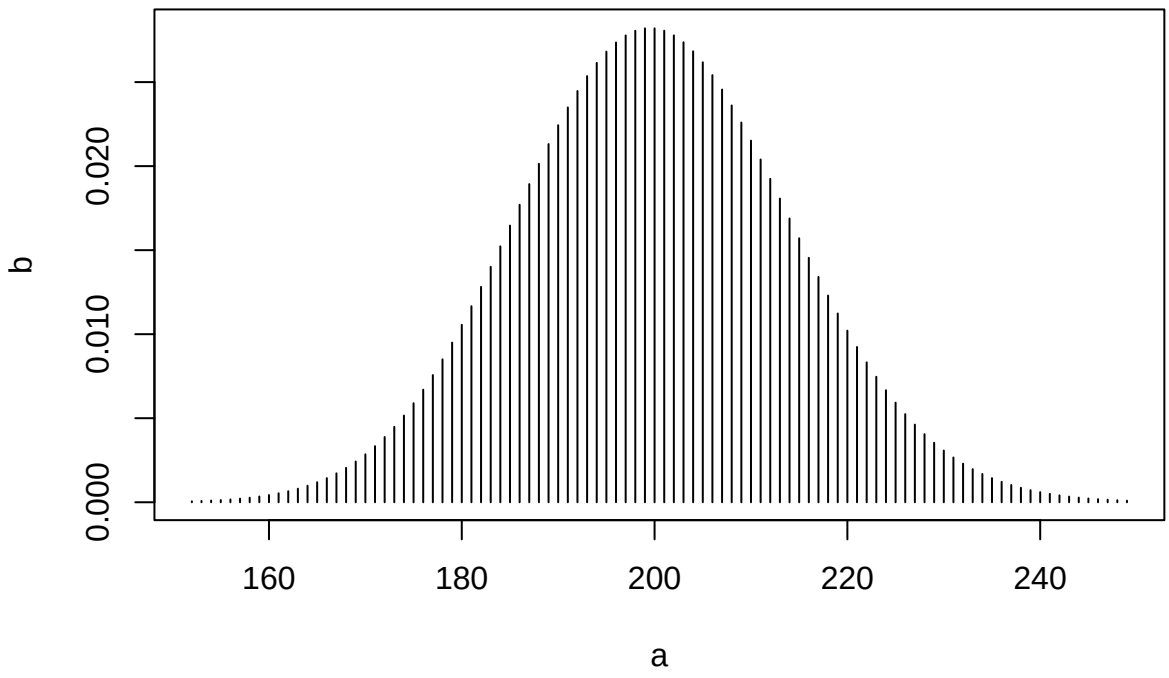


```
#Wykres dystrybuanty
a <- seq(min(X), max(X), by = 1)
b <- ppois(a, lambda)
plot(a,b)
```

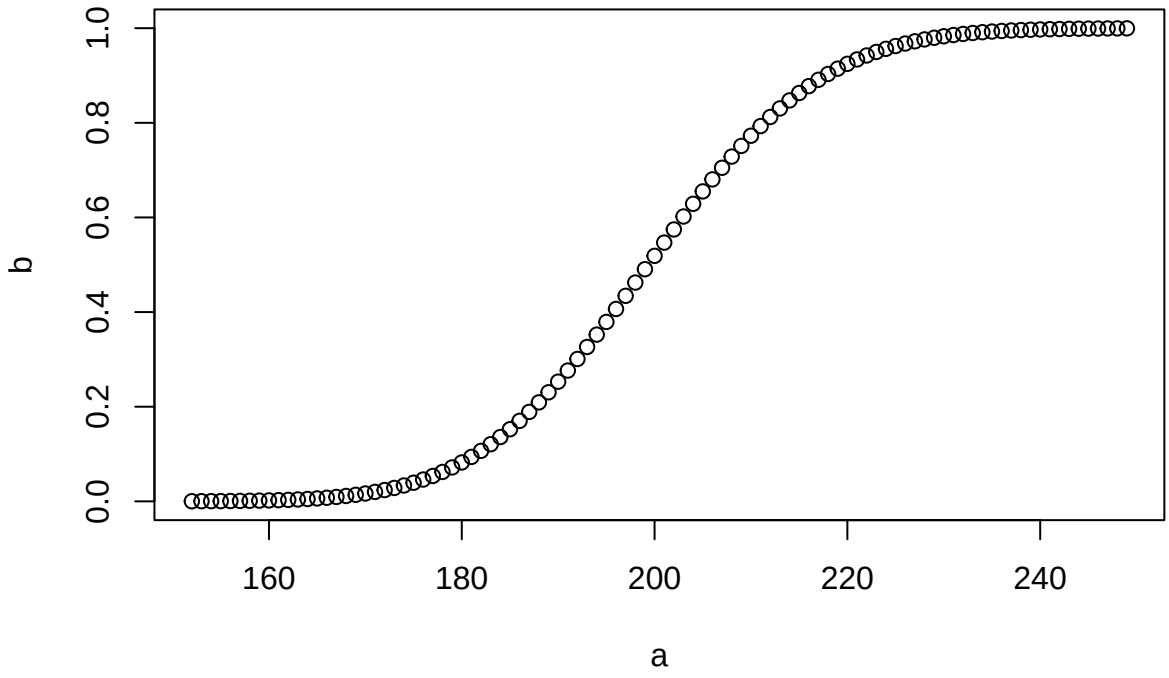

Rozkłady ciągłe

Rozkład normalny

```
#Generowanie próbki
N <- 1000
mu <- 7 # średnia
sigma <- 10 # odchylenie standardowe
X <- rnorm(N, mu, sigma)

#Prawdopodobieństwa
#Prawd. punktowe w rozkładzie ciągłym = 0
pnorm(10, mu, sigma) # P(X<=10) p. przedziałowe
```

```
## [1] 0.6179114
```

```
#Wykres gęstości
a <- seq(min(X), max(X), by = 0.5)
b <- dnorm(a, mu, sigma)
plot(a,b, type="h")
```

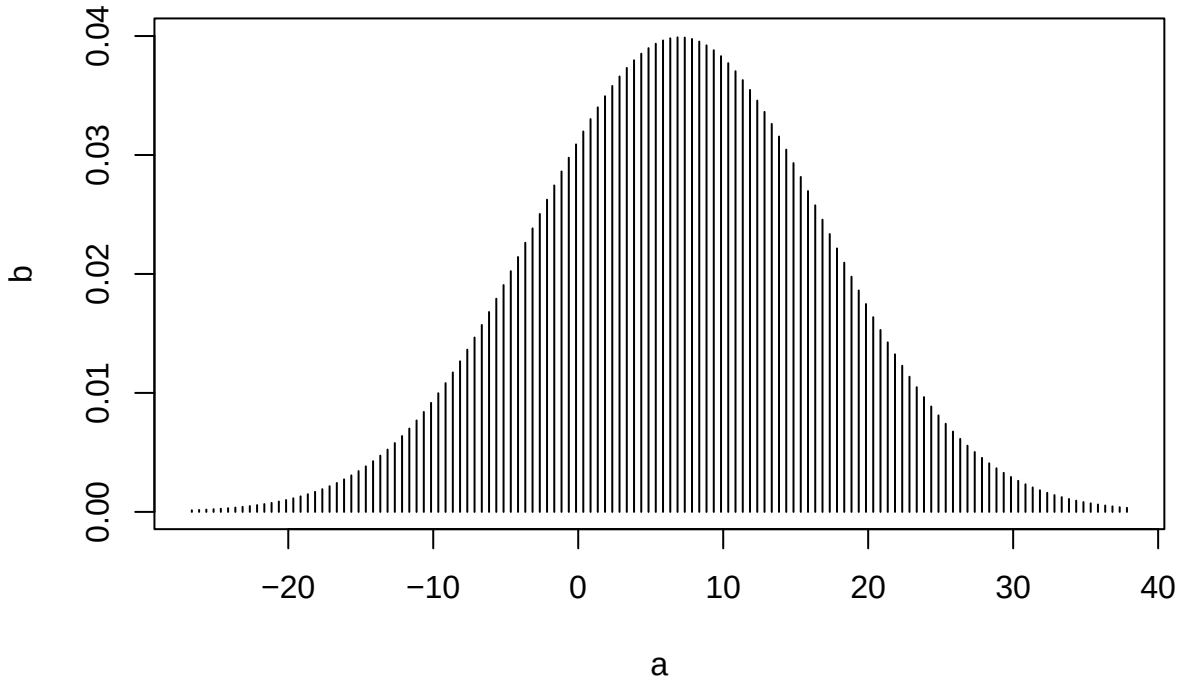


```
#Wykres dystrybuanty
a <- seq(min(X), max(X), by = 0.5)
b <- pnorm(a, mu, sigma)
plot(a,b)
```

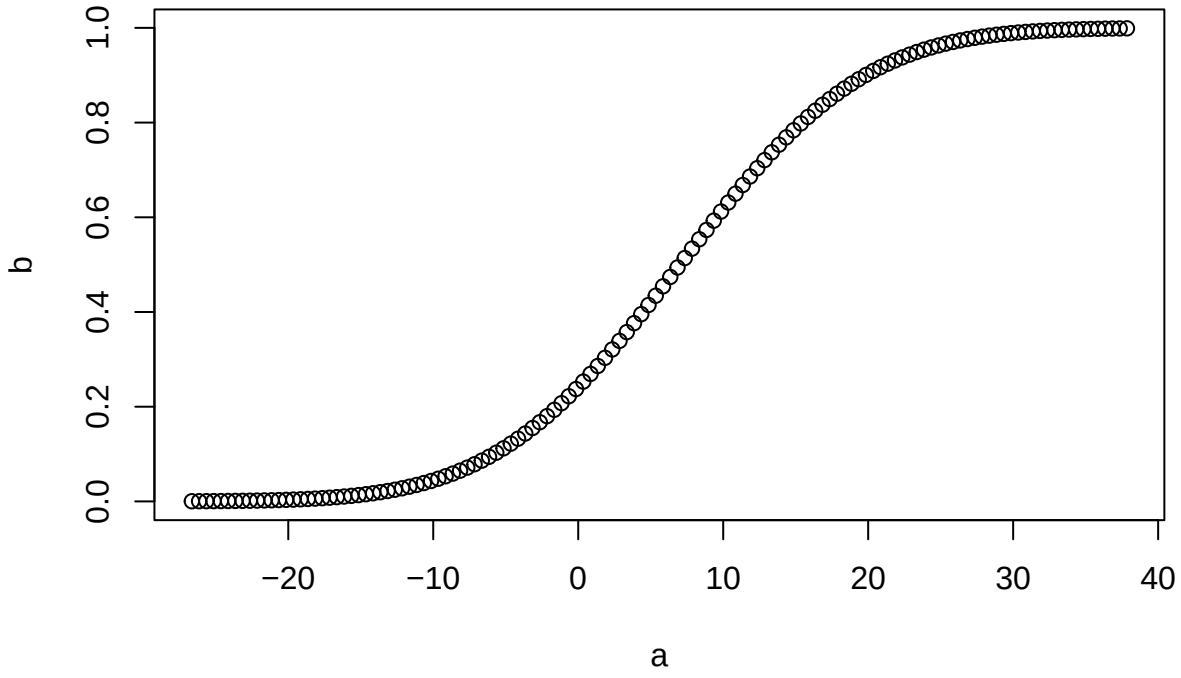

Rozkład Beta

```
#Generowanie próbki
N <- 1000
alpha <- 0.5
beta <- 0.5
X <- rbeta(N, alpha, beta)

#Prawdopodobieństwa
#Prawd. punktowe w rozkładzie ciągłym = 0
pbeta(0.7, alpha, beta) # P(X<=0.7) p. przedziałowe
```

```
## [1] 0.6309899
```

```
#Wykres gęstości
a <- seq(0, 1, by = 0.02)
b <- dbeta(a, alpha, beta)
plot(a,b, type="h")
```

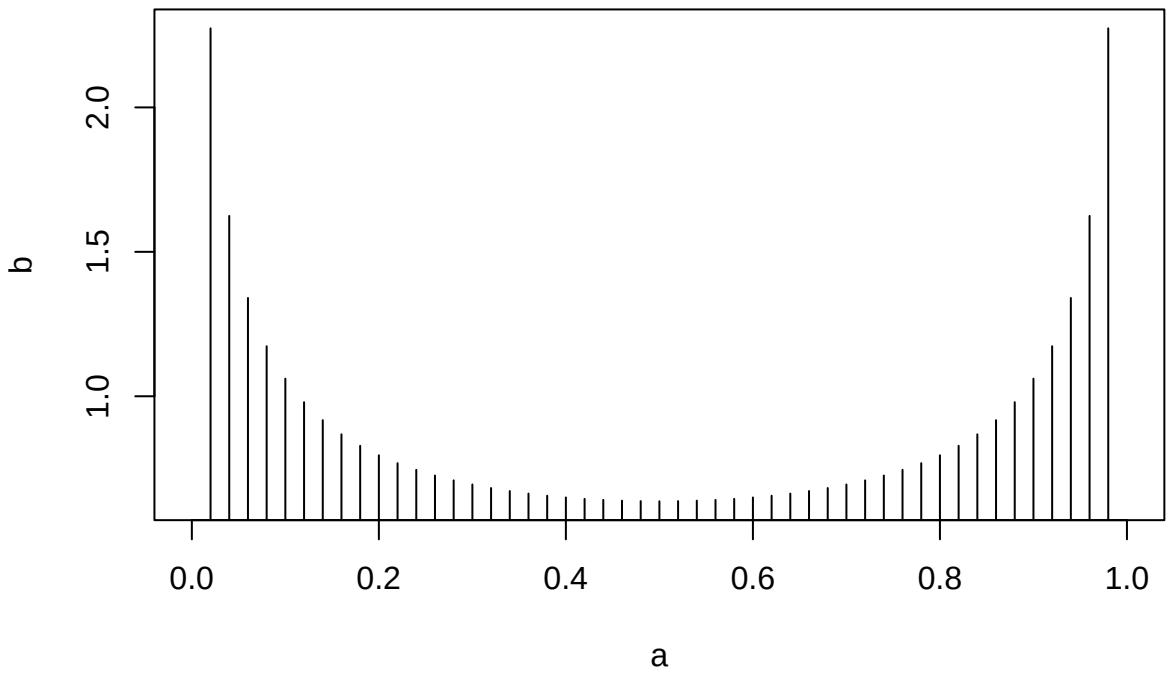


```
#Wykres dystrybuanty
a <- seq(0, 1, by = 0.02)
b <- pbeta(a, alpha, beta)
plot(a,b)
```

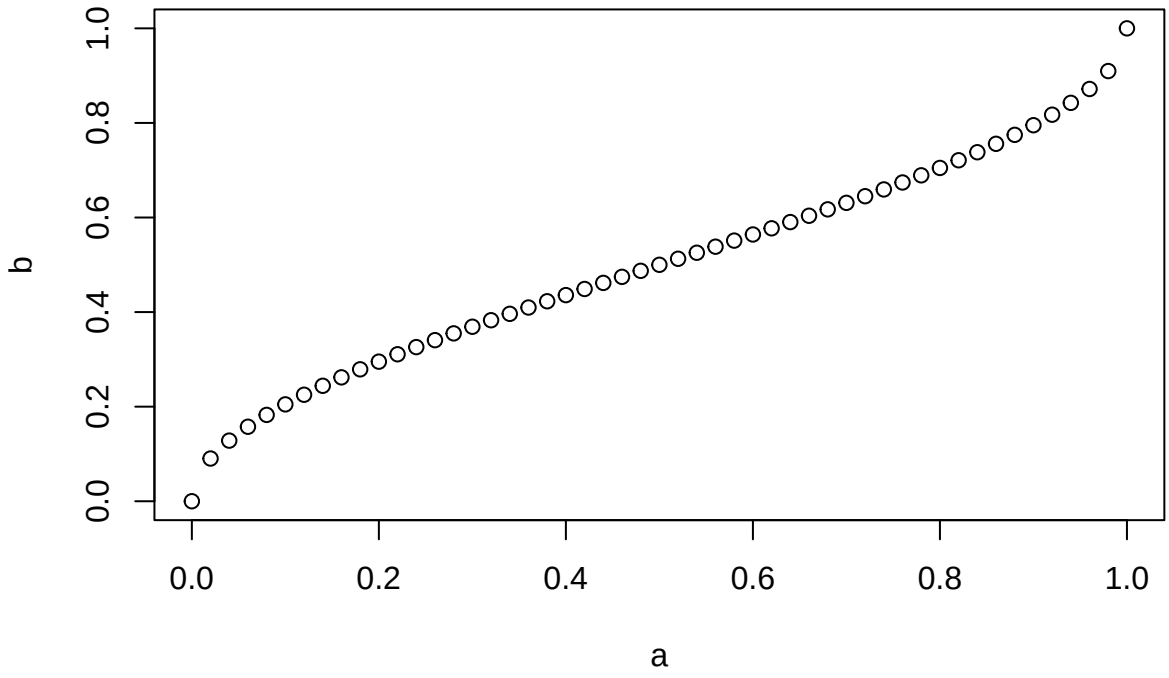

VI - Budowa macierzy z bazy danych

Do zbudowanie macierzy wykorzystano wszystkie dostępne numeryczne dane tj. *CenaPLN*, *KM*, *PrzebiegKm*, *RokProdukcji*, *PojemnoscSkokowa*. Dzięki temu możliwe jest wyznaczenie macierzy korelacji pomiędzy danymi.

```
# Select data
vi_database = data.matrix(select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TR
                    c("CenaPLN", "KM", "PrzebiegKm", "RokProdukcji", "PojemnoscSkokowa")))

#Is matrix
is.matrix(vi_database)
```

```
## [1] TRUE
```

```
#Display head
head(vi_database)
```

```
##      CenaPLN  KM PrzebiegKm RokProdukcji PojemnoscSkokowa
## [1,]   27900 150      80840         2005             1900
## [2,]   28000 116     166000         2004             2000
## [3,]   25500 150     112000         2002             1781
## [4,]   29900 109      42000         2005             1991
## [5,]   29800 207     169000         2004             2946
## [6,]   21400 122     160000         2003             1800
```

```
# Dimension
vi_dim <- dim(vi_database);
```

```r
cat("Rozmiar macierzy:", vi_dim[1], "x", vi_dim[2]);
```

```
## Rozmiar macierzy: 32776 x 5
```

```r
# Columns mean
vi_means = round(colMeans(vi_database), 3);
cat(paste(names(vi_means), vi_means, sep = " : ", collapse = ",\n"))
```

```
## CenaPLN : 29568.104,
## KM : 104.715,
## PrzebiegKm : 127770.544,
## RokProdukcji : 2005.09,
## PojemnoscSkokowa : 1742.825
```

```r
# Correlation
vi_corr_matrix = cor(vi_database);
print(vi_corr_matrix)
```

```
##                     CenaPLN         KM  PrzebiegKm RokProdukcji
## CenaPLN           1.0000000 0.53784100 -0.33277193   0.58752036
## KM                0.5378410 1.00000000  0.07887219   0.08579668
## PrzebiegKm       -0.3327719 0.07887219  1.00000000  -0.54240181
## RokProdukcji      0.5875204 0.08579668 -0.54240181   1.00000000
## PojemnoscSkokowa  0.4122382 0.74804407  0.26670668  -0.08499544
##                  PojemnoscSkokowa
## CenaPLN                 0.41223816
## KM                      0.74804407
## PrzebiegKm              0.26670668
## RokProdukcji           -0.08499544
## PojemnoscSkokowa        1.00000000
```

```r
corrplot(vi_corr_matrix, order = "hclust",
         tl.col = "black", tl.srt = 45)
```

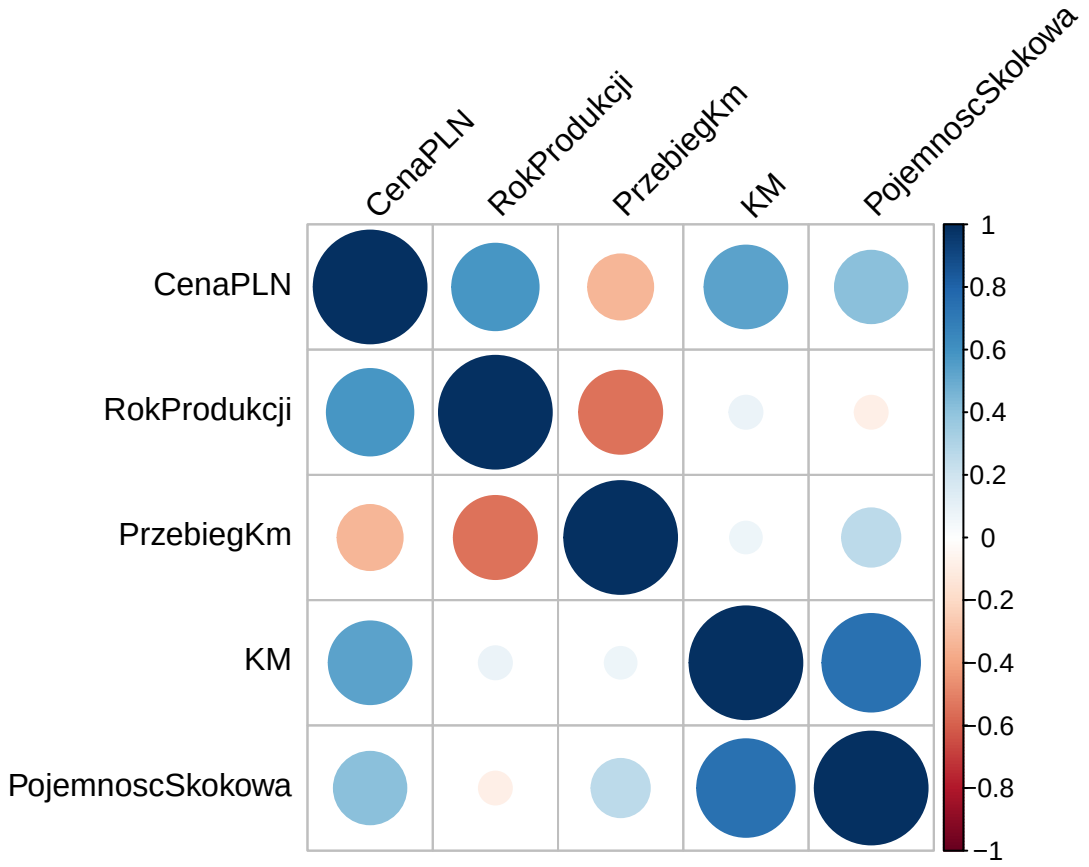

Jak można zaobserwować: - *CenaPLN* skorelowana jest z *RokProdukcji* (silnie), *KM*, *PojemnoscSkokowa* oraz odwrotnie z *PrzebiegKM*,
- *PojemnoscSkokowa* jest silnie skorelowana z ilością *KM* (większa pojemność -> więcej KM), - *PrzebiegKM* jest odwrotnie skorelowany z *RokProdukcji* (starszy samochód -> większy przebieg).

VII - Przedziały ufności

W tej sekcji przedstawione zostaną badania określające przedziały ufności z różnym stopniem 'zaufania'. Oznacza to, że jeśli grupa badana była zgromadzona w sposób losowy to rzeczywisty parametr populacji z z określonym stopniem 'zaufania' znajduje się w tym przedziale.

Zmienna numeryczna

W celu określnenia przedziałów ufności zmiennej numerycznej wybrano cechę *CenaPLN*.

Przedział ufności dla średniej:

Ze względu na dużą liczebność próby $n > 30$, przedział ufności dla średniej zgodnie z wzorem:

$$P\left(\overline{X} - u_{1-\frac{\alpha}{2}}\frac{s}{\sqrt{n}}, \overline{X} + u_{1-\frac{\alpha}{2}}\frac{s}{\sqrt{n}}\right) = 1 - \alpha$$

gdzie:

- $\overline{X}$ - średnia,
- n - to liczebność próby losowej,
- s - to odchylenie standardowe z próby,

- u_α - to wartość kwantyla $1 - \frac{\alpha}{2}$ rozkładu normalnego standaryzowanego dla poziomu istotności α .

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_price_mean = mean(database$CenaPLN);
vii_price_sd = sd(database$CenaPLN);
n = length(database$CenaPLN);

# Mean confidence function
mean_confidence <- function(mean, sd, n, confidence_level) {
  alpha = 1 - confidence_level;
  offset = qnorm(1 - alpha / 2) * sd / sqrt(n);
  lower_bound = mean - offset;
  upper_bound = mean + offset;
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
mean_confidence_intervals = sapply(confidence_level, function(conf_level) {
  mean_confidence(vii_price_mean, vii_price_sd, n, conf_level)
});

# Create matrix
mean_confidence_intervals = t(mean_confidence_intervals);
rownames(mean_confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(mean_confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności średniej dla różnych poziomów ufności:");
```

```
## [1] "Przedziały ufności średniej dla różnych poziomów ufności:"
```

```
print(mean_confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9         40431.08        41265.61
## Poziom ufności: 0.95        40351.15        41345.54
## Poziom ufności: 0.99        40194.91        41501.78
```

```
print(paste("Wartość średnia z próby:", round(vii_price_mean,2)));
```

```
## [1] "Wartość średnia z próby: 40848.35"
```

Przedział ufności dla odchylenia standardowego:

Ze względu na dużą liczebność próby $n > 30$, przedział ufności dla odchylenia standardowego zgodnie z wzorem:

$$P\left(\frac{S}{1+\frac{u_\alpha}{\sqrt{2n}}} < \sigma < \frac{S}{1-\frac{u_\alpha}{\sqrt{2n}}}\right) = 1 - \alpha$$

gdzie:

- n - to liczebność próby losowej,
- S - to odchylenie standardowe z próby,

- u_α - to wartość kwantyla $1 - \frac{\alpha}{2}$ rozkładu normalnego standaryzowanego dla poziomu istotności α .

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_price_mean = mean(database$CenaPLN);
vii_price_sd = sd(database$CenaPLN);
n = length(database$CenaPLN);

# SD confidence function
sd_confidence <- function(sd, n, confidence_level) {
  alpha = 1 - confidence_level;
  ua = qnorm(1 - alpha / 2);
  offset = ua  / sqrt(2*n);
  lower_bound = sd / (1 + offset);
  upper_bound = sd / (1 - offset);
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
sd_confidence_intervals = sapply(confidence_level, function(conf_level) {
  sd_confidence(vii_price_sd, n, conf_level);
});

# Create matrix
sd_confidence_intervals = t(sd_confidence_intervals);
rownames(sd_confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(sd_confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności odchylenia standardowego dla różnych poziomów ufności:");
```

```
## [1] "Przedziały ufności odchylenia standardowego dla różnych poziomów ufności:"
```

```
print(sd_confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9         51054.28        51644.40
## Poziom ufności: 0.95        50998.46        51701.64
## Poziom ufności: 0.99        50889.72        51813.89
```

```
print(paste("Wartość odchylenia standardowego z próby:", round(vii_price_sd,2)));
```

```
## [1] "Wartość odchylenia standardowego z próby: 51347.64"
```

Przedział ufności dla zmiennej jakościowej (frakcyjna)

Do wyznaczenia przedziału ufności dla zmiennej *PojazdUszkodzony*.

$p \in (\frac{m}{n} \breve{} u_{1-\frac{\alpha}{2}} \frac{\sqrt{\frac{m}{n} \cdot (1-\frac{m}{n})}}{\sqrt{n}}, \frac{m}{n} + u_{1-\frac{\alpha}{2}} \frac{\sqrt{\frac{m}{n} \cdot (1-\frac{m}{n})}}{\sqrt{n}})$

gdzie:

m - ilość zdarzeń sprzyjających,

n - ilość wszystkich zdarzeń,

- u_α - to wartość kwantyla $1 - \frac{\alpha}{2}$ rozkładu normalnego standaryzowanego dla poziomu istotności α .

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_positive = sum(database$PojazdUszkodzony == TRUE);
vii_all      = length(database$PojazdUszkodzony);

mean_bool_confidence <- function(m, n, confidence_level) {
  alpha = 1 - confidence_level;
  mn = m / n;
  offset = qnorm(1 - alpha / 2) * sqrt(mn * (1-mn)) / sqrt(n);
  lower_bound = mn - offset;
  upper_bound = mn + offset;
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
confidence_intervals = sapply(confidence_level, function(conf_level) {
  mean_bool_confidence(vii_positive, vii_all, conf_level);
});

# Create matrix
confidence_intervals = t(confidence_intervals);
rownames(confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności dla frakcji dla różnych poziomów ufności (Udział pojazdów uszkodzonych):");
```

```
## [1] "Przedziały ufności dla frakcji dla różnych poziomów ufności (Udział pojazdów uszkodzonych):"
```

```
print(confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9       0.03446330      0.03749003
## Poziom ufności: 0.95      0.03417338      0.03777995
## Poziom ufności: 0.99      0.03360675      0.03834658
```

```
print(paste("Udział pojazdów uszkodzonych w zbiorze ", round(vii_positive/length(database$PojazdUszkodz
```

```
## [1] "Udział pojazdów uszkodzonych w zbiorze  0.04"
```

Przedział ufności dla zmiennej jakościowej

Do analizy wybrano pole *Marka*.

```
vii_marka = database %>% group_by(database$Marka) %>% summarise(percent = n()/length(database$Marka));
```

Przedział ufności dla średniaj z udziału *Marki* w zbiorze

Ze względu na mała liczebność próby $n < 30$, przedział ufności dla odchylenia standardowego zgodnie z wzorem:

$P(\overline{X} - t_{\alpha,n-1}\frac{s}{\sqrt{n}}, \overline{X} + t_{\alpha,n-1}\frac{s}{\sqrt{n}}) = 1 - \alpha$

gdzie:

- $\overline{X}$ - średnia,
- n - to liczebność próby losowej,
- s - to odchylenie standardowe z próby,
- $t_{\alpha,n-1}$ - dystrybuanta rozkładu t-studenta dla 1-a i n-1 stopni swobody.

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_marka_mean = mean(vii_marka$percent);
vii_marka_sd = sd(vii_marka$percent);
n = length(vii_marka$percent);

# Mean confidence function
mean_confidence <- function(mean, sd, n, confidence_level) {
  alpha = 1 - confidence_level;
  offset = pt(alpha, n-1) * sd / sqrt(n);
  lower_bound = mean - offset;
  upper_bound = mean + offset;
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
mean_confidence_intervals = sapply(confidence_level, function(conf_level) {
  mean_confidence(vii_marka_mean, vii_marka_sd, n, conf_level)
});

# Create matrix
mean_confidence_intervals = t(mean_confidence_intervals);
rownames(mean_confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(mean_confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności średniej z danych jakościowych dla różnych poziomów ufności:");
```

```
## [1] "Przedziały ufności średniej z danych jakościowych dla różnych poziomów ufności:"
```

```
print(mean_confidence_intervals);
```

```
##                      Dolny przedział Górny przedział
## Poziom ufności: 0.9       0.08539988      0.09641830
## Poziom ufności: 0.95      0.08559816      0.09622002
## Poziom ufności: 0.99      0.08575720      0.09606098
```

```
print(paste("Wartość średnia z próby:", round(vii_marka_mean, 3)));
```

```
## [1] "Wartość średnia z próby: 0.091"
```

Przedział ufności dla średniaj z udziału *Marki* w zbiorze

Ze względu na mała liczebność próby $n < 30$, przedział ufności dla odchylenia standardowego zgodnie z wzorem:

$$P\left(\frac{n \cdot S^2}{\chi^2_{1-\frac{\alpha}{2},n-1}} < \sigma^2 < \frac{n \cdot S^2}{\chi^2_{\frac{\alpha}{2},n-1}}\right) = 1 - \alpha$$

gdzie:

- n - to liczebność próby losowej,
- S - to odchylenie standardowe z próby,
- $\chi_{1-\frac{\alpha}{2},n-1}$ - kwantyle rozkładu Chi-kwadrat 1-a i n-1 stopni swobody.

```
# Meta data
# Confidence level 0.9, 0.95, 0.99
confidence_level = c(0.9, 0.95, 0.99);

# Basic data
vii_marka_mean = mean(vii_marka$percent);
vii_marka_sd = sd(vii_marka$percent);
n = length(vii_marka$percent);

# Mean confidence function
sd_confidence <- function(sd, n, confidence_level) {
  alpha = 1 - confidence_level;
  lower_bound = sqrt((n * sd * sd) / (qchisq(1-alpha/2, n-1)));
  upper_bound = sqrt((n * sd * sd) / (qchisq(alpha/2, n-1)));
  return(c(lower_bound, upper_bound));
};

# Calculate confidence
sd_confidence_intervals = sapply(confidence_level, function(conf_level) {
  sd_confidence(vii_marka_sd, n, conf_level);
});

# Create matrix
sd_confidence_intervals = t(sd_confidence_intervals);
rownames(sd_confidence_intervals) = paste0("Poziom ufności: ", confidence_level);
colnames(sd_confidence_intervals) = c("Dolny przedział", "Górny przedział");

# Display
print("Przedziały ufności odchylenia standardowego dla różnych poziomów ufności:");
```

```
## [1] "Przedziały ufności odchylenia standardowego dla różnych poziomów ufności:"
```

```
print(sd_confidence_intervals);
```

```
##                       Dolny przedział Górny przedział
## Poziom ufności: 0.9        0.02628534      0.05665759
## Poziom ufności: 0.95       0.02484986      0.06241419
## Poziom ufności: 0.99       0.02240909      0.07659717
```

```
print(paste("Wartość odchylenia standardowego z próby:", round(vii_marka_sd,2)));
```

```
## [1] "Wartość odchylenia standardowego z próby: 0.03"
```

VIII - Testowanie hipotez

Zmienne jakościowe

Test niezależności

Za pomocą testu niezależności χ^2 sprawdzona zostanie niezależność pomiędzy Marką a udziałem w nich samochodów ze skrzynią mechaniczną.

Hipoteza:

H_0 - udział skrznyni mechanicznej jest niezależny od marki,

H_1 - udział skrznyni mechanicznej jest zależny od marki,

Poziom istotności $\alpha = 0.05$.

```
vii_cross = table(database$Marka, database$SkrzyniaBiegowManualna)
vii_table = data.frame(Marka=rownames(vii_cross), UdzialSkrzyniManualnej = (vii_cross[,2]/(vii_cross[,1
```

```
ggplot(vii_table, aes(y=Marka, x=UdzialSkrzyniManualnej)) +
    geom_bar(position="dodge", stat="identity", fill="orange")+
    ggtitle("Udział samochodów z skrzynią manualną")
```

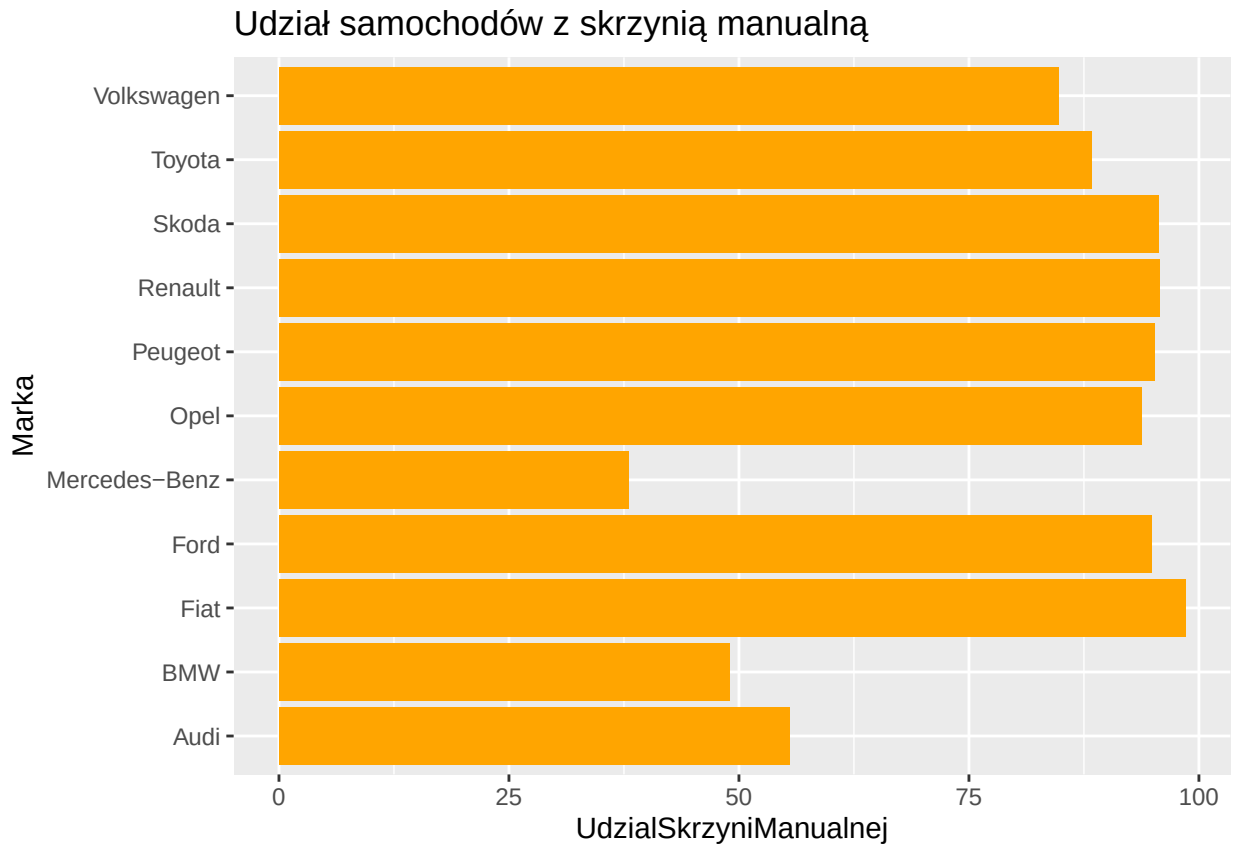


```
chisq.test(vii_cross)
```

```
##
##  Pearson's Chi-squared test
##
## data:  vii_cross
```

```
## X-squared = 10428, df = 10, p-value < 2.2e-16
```

Zgodnie z wynikiem testu mamy podstawy do odrzucenia hipotezy zerowej na korzyść hipotezy alternatywnej - udział skrznyni mechanicznej jest zależny od marki.

Test proporcji

Test proporcji pozwala odpowiedzieć na pytanie czy odsetki w jednej, dwóch lub więcej grupach różnią się od siebie istotnie.

Hipoteza:

H_0 - odsetek pojazdów uszkodzonych jest niezależny od kraju pochodzenia,

H_1 - odsetek pojazdów uszkodzonych jest zależny od kraju pochodzenia,

Poziom istotności $\alpha = 0.05$.

```
vii_proporcja = database %>% group_by(KrajPochodzenia) %>% summarise(Liczebnosc = n());
vii_proporcja$Uszkodzonych = table(database$KrajPochodzenia, database$PojazdUszkodzony)[,2];
vii_proporcja$ProcentUszkodzonych = (vii_proporcja$Uszkodzonych / vii_proporcja$Liczebnosc) * 100;
vii_proporcja = vii_proporcja %>% filter(Liczebnosc > 1000);

ggplot(vii_proporcja, aes(y=KrajPochodzenia, x=ProcentUszkodzonych)) +
    geom_bar(position="dodge", stat="identity", fill="orange")+
    ggtitle("Procent pojazdów uszkodzonych")
```

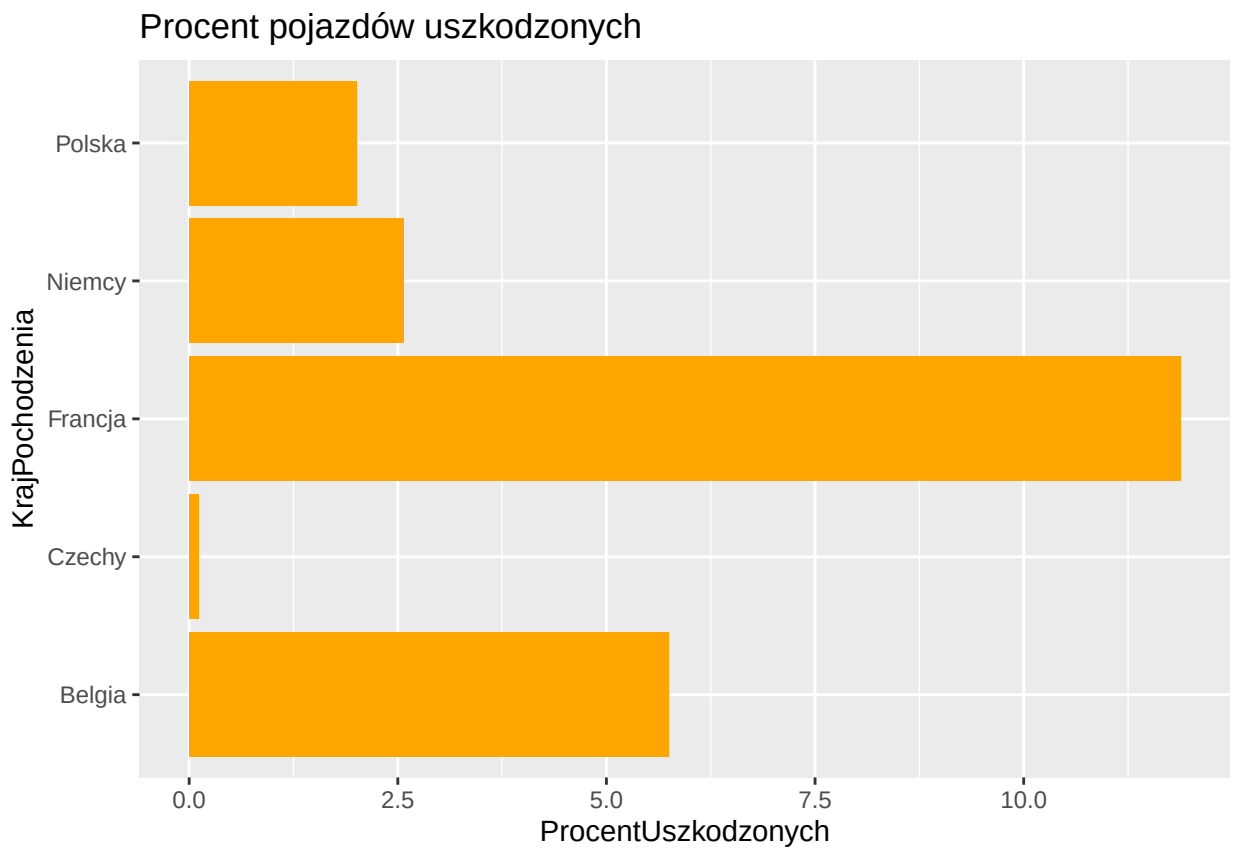


```
vii_test = prop.test(x = vii_proporcja$Uszkodzonych, n = vii_proporcja$Liczebnosc);
print(vii_test);
```

```
##
##  5-sample test for equality of proportions without continuity
##  correction
##
## data:  vii_proporcja$Uszkodzonych out of vii_proporcja$Liczebnosc
## X-squared = 1074.4, df = 4, p-value < 2.2e-16
## alternative hypothesis: two.sided
## sample estimates:
##      prop 1      prop 2      prop 3      prop 4      prop 5
## 0.057422969 0.001156961 0.118827568 0.025647319 0.020011482
```

Zgodnie z wynikiem testu mamy podstawy do odrzucenia hipotezy zerowej na korzyść hipotezy alternatywnej - odsetek pojazdów uszkodzonych jest zależny od kraju pochodzenia.

Zmienne ilościowe

Test normalności

Test umożliwia weryfikację czy cecha ma rozkłada normalny.

Hipoteza:

H_0 - cena pojazdów ma rozkład normalny,

H_1 - cena pojazdów nie ma rozkładu normalnego,

Poziom istotności $\alpha = 0.05$.

```
vii_test = ad.test(database$CenaPLN);
print(vii_test);
```

```
##
##  Anderson-Darling normality test
##
## data:  database$CenaPLN
## A = 5521.3, p-value < 2.2e-16
```

```
ggplot(database, aes(sample = CenaPLN)) +
  stat_qq() +
  stat_qq_line(color="red");
```

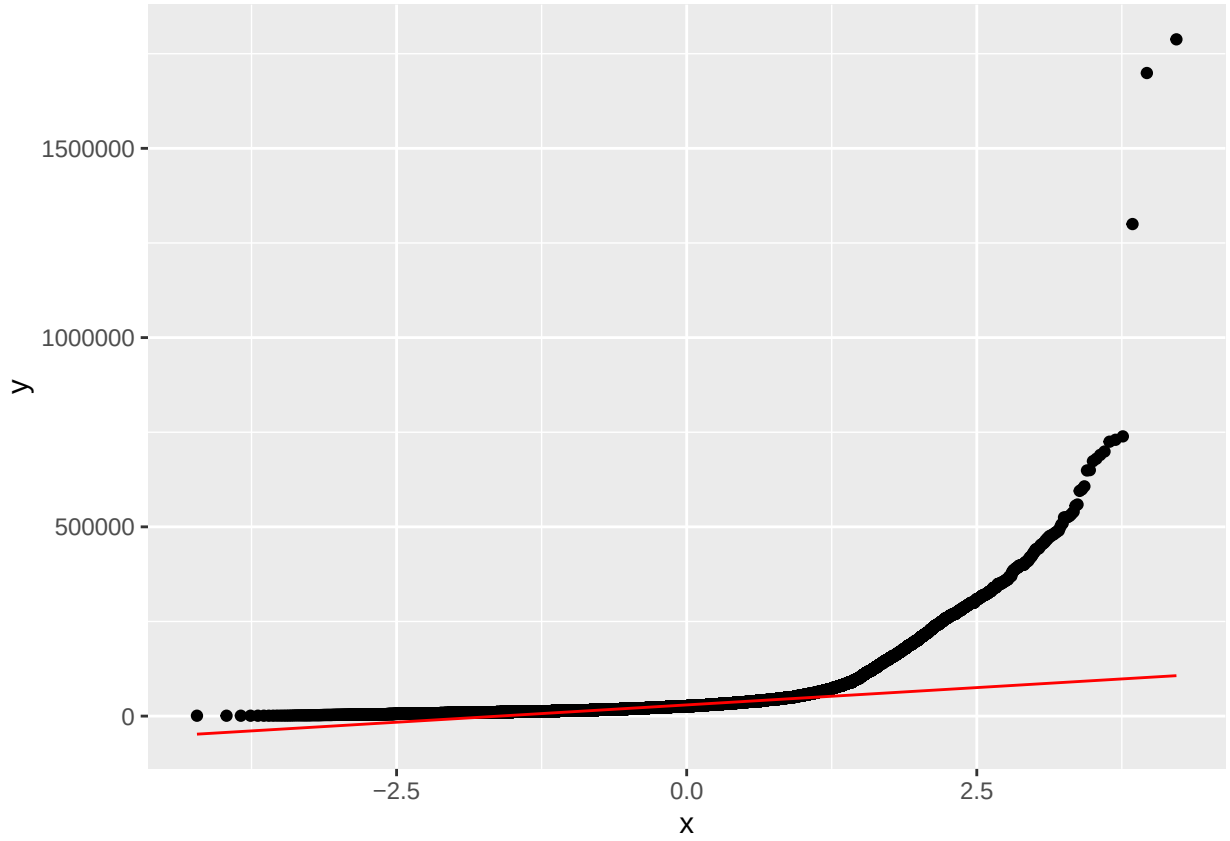

Zgodnie z wynikiem testu mamy podstawy do odrzucenia hipotezy zerowej na korzyść hipotezy alternatywnej - cena pojazdów nie ma rozkładu normalnego.

Test średnich

Ze względu na to, iż cena nie jest zmienną o rozkładzie normalnym. Wykorzystujemy nieparametryczny test Wilcoxona.

Hipoteza:

H_0 - średnia jest równa 41000,

H_1 - średnia nie jest równa 41000,

Poziom istotności $\alpha = 0.05$.

```
wilcox.test(x = database$CenaPLN, mu = 41000)
```

```
##
##  Wilcoxon signed rank test with continuity correction
##
## data:  database$CenaPLN
## V = 238698925, p-value < 2.2e-16
## alternative hypothesis: true location is not equal to 41000
```

Zgodnie z wynikiem testu mamy podstawy do odrzucenia hipotezy zerowej na korzyść hipotezy alternatywnej - średnia nie jest równa 41000.

IX - Regresja liniowa i inne

Modele dla jednej zmiennej

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "PrzebiegKm"))
model = lm(CenaPLN ~ . , data = ix_database)
ix_sample = ix_database[sample(nrow(ix_database), size=1000),]
plot(CenaPLN ~ PrzebiegKm,  data=ix_sample, col = 'darkcyan')
abline(model, col="red")
```

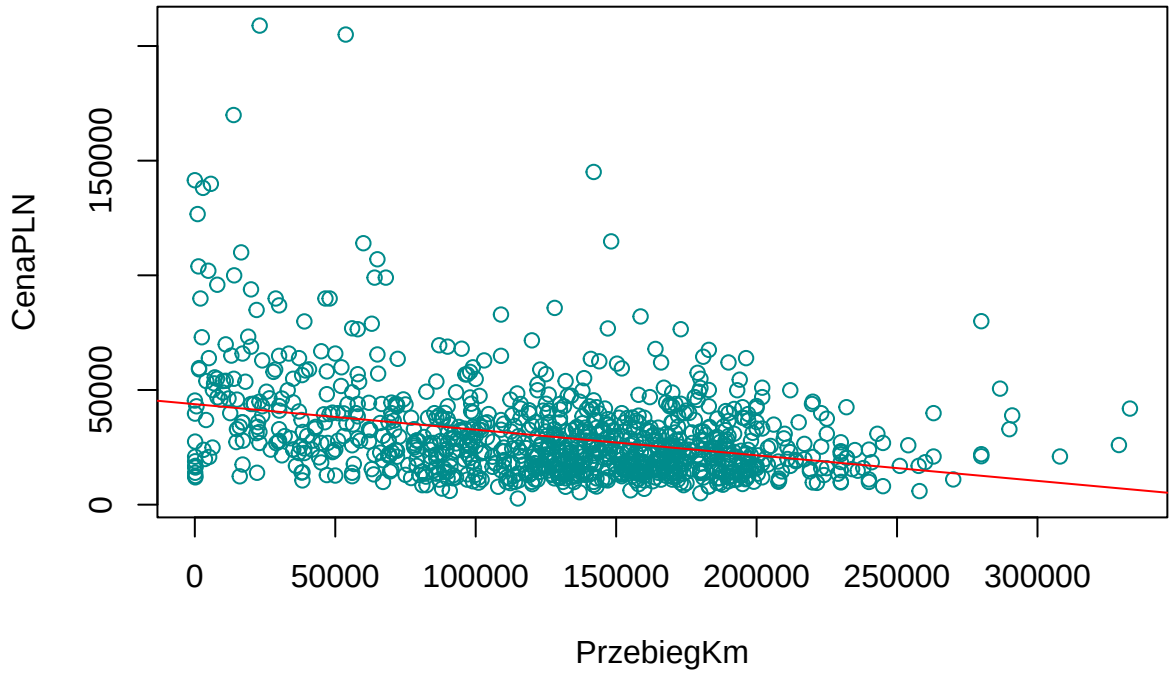


```
summary(model);
```

```
##
## Call:
## lm(formula = CenaPLN ~ ., data = ix_database)
##
## Residuals:
##    Min     1Q Median     3Q    Max
## -39901 -11905  -4136   6516 637321
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.382e+04  2.507e+02  174.76   <2e-16 ***
## PrzebiegKm  -1.115e-01  1.746e-03  -63.88   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 20740 on 32774 degrees of freedom
## Multiple R-squared:  0.1107, Adjusted R-squared:  0.1107
## F-statistic:  4081 on 1 and 32774 DF,  p-value: < 2.2e-16
```

```
print(model$coefficients);
```

```
##  (Intercept)   PrzebiegKm
## 43817.457268    -0.111523
```

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "PojemnoscSkokowa"))
model = lm(CenaPLN ~ . , data = ix_database)
ix_sample = ix_database[sample(nrow(ix_database), size=1000),]
plot(CenaPLN ~ PojemnoscSkokowa,  data=ix_sample, col = 'darkcyan')
abline(model, col="red")
```

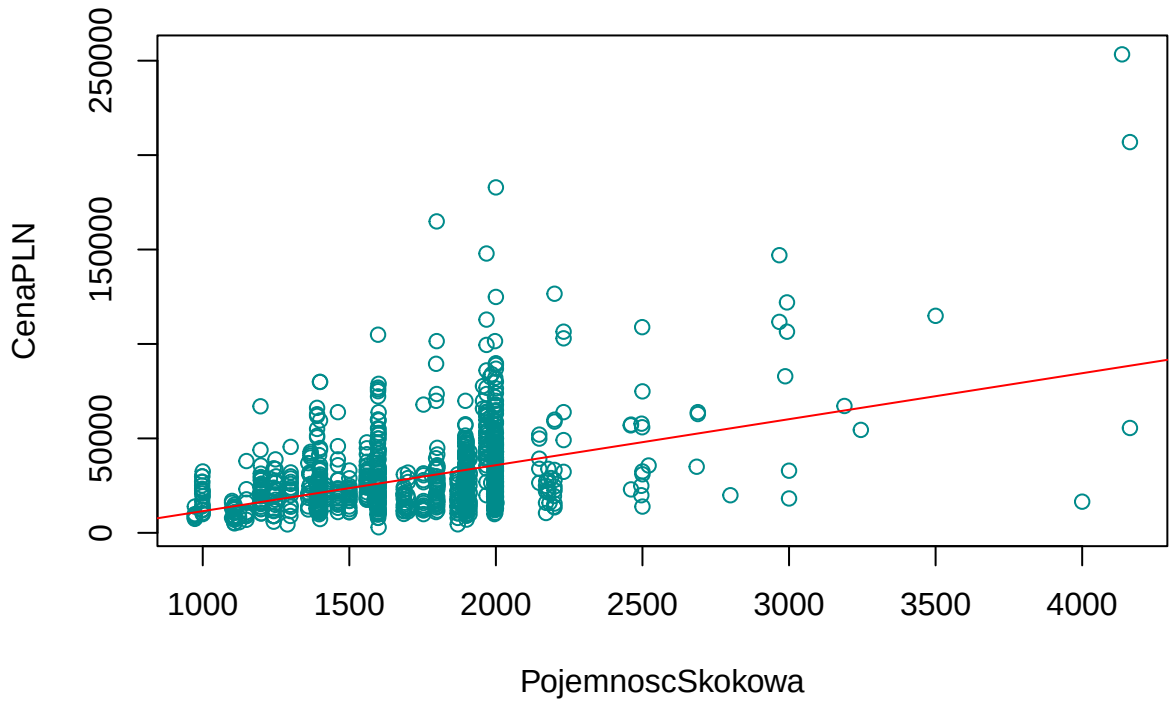


```
summary(model);
```

```
##
## Call:
## lm(formula = CenaPLN ~ ., data = ix_database)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -124863  -11495   -3285    6505  566066
##
## Coefficients:
```

```
##                    Estimate Std. Error t value Pr(>|t|)
## (Intercept)      -1.286e+04  5.297e+02  -24.28   <2e-16 ***
## PojemnoscSkokowa  2.435e+01  2.972e-01   81.91   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 20030 on 32774 degrees of freedom
## Multiple R-squared:  0.1699, Adjusted R-squared:  0.1699
## F-statistic:  6710 on 1 and 32774 DF,  p-value: < 2.2e-16
```

```
print(model$coefficients);
```

```
##      (Intercept) PojemnoscSkokowa
##     -12862.74176         24.34602
```

Modele dla 2 zmiennych

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "PrzebiegKm", "PojemnoscSkokowa"))
model = lm(CenaPLN ~ . , data = ix_database)

plot3d(model, col='darkcyan', plane.col = 'red')
rglwidget()
```

```
## Warning in snapshot3d(scene = x, width = width, height = height): webshot =
## TRUE requires the webshot2 package and Chrome browser; using rgl.snapshot()
## instead
```

```
## Warning in rgl.snapshot(filename, fmt, top): this build of rgl does not support
## snapshots
```

```
summary(model);
```

```
##
## Call:
## lm(formula = CenaPLN ~ ., data = ix_database)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -167185   -9096   -1707    6209  521446
##
## Coefficients:
##                    Estimate Std. Error t value Pr(>|t|)
## (Intercept)      -5.538e+03  4.627e+02  -11.97   <2e-16 ***
## PrzebiegKm       -1.597e-01  1.511e-03 -105.69   <2e-16 ***
## PojemnoscSkokowa  3.185e+01  2.663e-01  119.61   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 17300 on 32773 degrees of freedom
## Multiple R-squared:  0.3809, Adjusted R-squared:  0.3809
## F-statistic: 1.008e+04 on 2 and 32773 DF,  p-value: < 2.2e-16
```

```
print(model$coefficients);
```

```
##      (Intercept)       PrzebiegKm PojemnoscSkokowa
##    -5537.7325250       -0.1597319       31.8533893
```

Drzewa decyzyjne

```
ix_database = select(filter(database, PojazdUszkodzony==FALSE & SkrzyniaBiegowManualna == TRUE),
                     c("CenaPLN", "RokProdukcji", "PojemnoscSkokowa"))
ix_data_split = initial_split(ix_database, prop = 0.75);
ix_train_data <- training(ix_data_split);
ix_test_data <- testing(ix_data_split);

tree_spec <- decision_tree() %>%
 set_engine("rpart") %>%
 set_mode("regression")

tree_fit <- tree_spec %>%
 fit(CenaPLN ~ ., data = ix_train_data)

predictions <- tree_fit %>%
 predict(ix_test_data) %>%
 pull(.pred)

metrics <- metric_set(rmse, rsq)
model_performance <- ix_test_data %>%
 mutate(predictions = predictions) %>%
 metrics(truth = CenaPLN, estimate = predictions)

print(model_performance)
```

```
## # A tibble: 2 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 rmse    standard   12300.
## 2 rsq     standard       0.675
```

```
rpart.plot(tree_fit$fit, type = 5, extra = 101, under = TRUE, cex = 0.8, box.palette = "auto")
```

```
## Warning: Cannot retrieve the data used to build the model (so cannot determine roundint and is.binary
## To silence this warning:
##     Call rpart.plot with roundint=FALSE,
##     or rebuild the rpart model with model=TRUE.
```

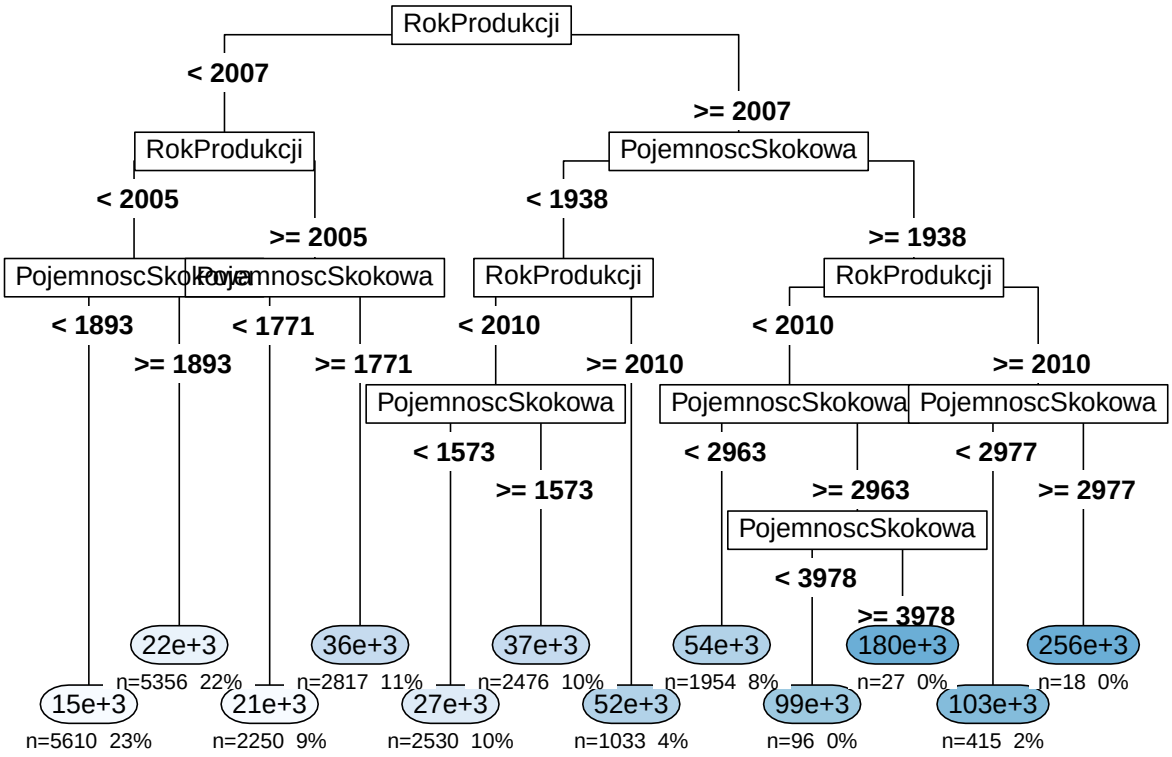
RokProdukcji
< 2007
>= 2007
RokProdukcji
PojemnoscSkokowa
< 2005
>= 2005
< 1938
>= 1938
PojemnoscSkokowa
PojemnoscSkokowa
RokProdukcji
RokProdukcji
< 1893
>= 1893
< 1771
>= 1771
< 2010
>= 2010
< 2010
>= 2010
PojemnoscSkokowa
PojemnoscSkokowa
PojemnoscSkokowa
< 1573
>= 1573
< 2963
>= 2963
< 2977
>= 2977
PojemnoscSkokowa
< 3978
>= 3978
22e+3
n=5356 22%
36e+3
n=2817 11%
37e+3
n=2476 10%
54e+3
n=1954 8%
180e+3
n=27 0%
256e+3
n=18 0%
15e+3
n=5610 23%
21e+3
n=2250 9%
27e+3
n=2530 10%
52e+3
n=1033 4%
99e+3
n=96 0%
103e+3
n=415 2%